

硕士学位论文

融合激光点云和光学图像数据的混凝土桥墩 裂缝三维定量检测方法研究

**Research on 3D Quantitative Detection Methods for Concrete
Pier Cracks Based on Fused Laser Point Clouds and Image Data**

作者姓名：_____李春晓_____

学号：_____22206124_____

指导教师：_____覃晖 副教授_____

学科、专业：_____桥梁与隧道工程_____

答辩日期：_____2025 年 6 月_____

大连理工大学

Dalian University of Technology

摘 要

改革开放以来,我国桥梁建设已进入“建养并重”阶段。随着桥梁数量的增加及其使用年限的延长,病害检测与维护管理变得尤为重要。桥墩是桥梁的重要结构,开发高效、精准的桥墩病害检测方法对于实现桥梁的全生命周期管理意义重大。裂缝是混凝土桥墩常见的病害,传统的人工目视检查效率低,难以精确量化裂缝,无法满足快速定量分析的需求。因此,亟需开发桥墩裂缝的快速三维定位和量化方法。

针对上述问题,本文研究了一种基于激光点云和图像数据的混凝土桥墩裂缝三维定量检测方法,旨在提高桥梁病害的识别与量化精度,主要研究和成果如下:

首先,提出了一种基于 LiDAR 点云的桥墩 BIM 模型构建方法,通过点云采集、预处理、分割和参数提取,提出了矩形截面、圆形截面、圆端形截面桥墩的参数化建模方法,并分析了参数的误差影响。

其次,开发了一种基于深度学习 LoFTR 模型的点云强度图与光学图片配准方法,将点云转换为特征明显的点云强度图以进行配准,基于 LoFTR 拼接光学图片以扩展图片的场景,增加更多的特征,基于 LoFTR 对点云强度图和光学图片进行配准,增强点云强度图中轮廓线特征以提升配准效果,得到了点云和光学图片的对应关系,以此得到了光学图片的分辨率,为下一步病害识别奠定了基础。

最后,开发了裂缝识别和量化方法,将 CBAM 加入 YOLOv8-seg 模型的主干特征提取网络中,提出了 YOLOv8-CBAM-seg 模型,在基于 SDNet2018 的数据集上进行训练、验证和测试,其在精确率(96.7%)和 $mAP@50$ (94.9%)方面优于 U-Net、YOLOv8-seg 等其他方法;提出了基于骨架和图的裂缝宽度量化算法,其中包含基于形态学的裂缝交叉点去除和基于 DFS 的裂缝骨架剪枝算法,以及在骨架点上进行宽度量化的 EOB 算法。基于 DFS 的裂缝骨架剪枝算法与 DSE 算法相比不依赖于参数指定,且时间复杂度更低。与 ESD、OB 等算法进行结果比较,EOB 算法结果更为合理,在真实骨架固定宽度的拟合数据集上的相对误差的平均值为-5.3%,证明了其量化的准确性较高。

在工程验证中,基于 LiDAR 点云建立圆端形截面桥墩模型,其截面参数的提取误差小于 LiDAR 的精度,建模效果较好。在点云强度图和光学图片配准环节,与传统特征点提取方法(如 SIFT 和 SURF)相比,基于深度学习的 LoFTR 算法在低纹理表面上增加了特征点的数量,匹配准确性提高近 100%。当增强轮廓线特征时,正确匹配点的数量比原始 LoFTR 算法增加了 64%,证明了轮廓线特征增强策略的有效性。在裂缝的识别和量化方面,桥墩正面的模拟裂缝的量化的相对误差均值为 2.48%,相对误差标准差为 8.49%;桥墩侧面的模拟裂缝的相对误差均值为 11.74%,相对误差标准差为 13.57%,

而位于桥墩正面的真实裂缝的量化相对误差为-11.25%，结果表明，本文方法在平面表面上的准确性和稳定性优于曲面表面，裂缝宽度量化的相对误差在可接受范围内，且具有较高的实时处理能力。本文还在点云上三维展示裂缝，并建立了全桥的 BIM 模型结果展示。

综上所述，本文提出的基于激光点云和光学图像数据的混凝土桥墩裂缝三维定量检测方法在桥梁病害检测领域具有重要的理论意义和工程应用价值。

关键词：激光点云；图像数据；桥梁病害；三维检测；深度学习

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外相关研究工作进展	2
1.2.1 BIM 模型快速构建方法	2
1.2.2 裂缝识别和量化方法.....	3
1.3 论文研究思路及目标.....	5
1.3.1 主要研究内容.....	5
1.3.2 技术路线图.....	6
2 基于 LiDAR 点云的桥墩三维建模方法	8
2.1 引言.....	8
2.2 LiDAR 点云采集.....	8
2.3 LiDAR 点云预处理.....	9
2.3.1 CloudCompare 软件	9
2.3.2 噪声去除	10
2.3.3 点云配准	12
2.4 BIM 模型构建	13
2.4.1 桥墩截面类型及其 BIM 模型构建方法.....	13
2.4.2 矩形截面桥墩的 BIM 构建	17
2.4.3 圆形截面桥墩的 BIM 构建	21
2.4.4 圆端形截面桥墩的 BIM 构建	24
2.5 本章小结.....	27
3 点云强度图和光学图片配准方法	28
3.1 引言.....	28
3.2 点云强度图生成.....	28
3.3 光学图片拼接.....	30
3.3.1 最小可检测宽度	30
3.3.2 基于 LoFTR 的光学图像拼接方法.....	31
3.3.3 图像拼接方法实例验证.....	33
3.4 基于 LoFTR 的点云强度图和光学图片配准算法	36
3.4.1 点云强度图的下采样与轮廓线特征增强	36
3.4.2 图像配准算法.....	37
3.5 本章小结.....	39
4 裂缝识别与量化	40
4.1 引言.....	40

4.2 基于深度学习的裂缝实例分割	40
4.2.1 YOLOv8-seg-CBAM	40
4.2.2 算法训练、测试	42
4.3 基于骨架和图的裂缝量化	45
4.3.1 裂缝骨架提取	45
4.3.2 基于形态学操作的裂缝交叉点去除算法	46
4.3.3 基于 DFS 的裂缝骨架剪枝和长度计算	48
4.3.4 EOB 算法计算裂缝宽度	50
4.4 本章小结	54
5 工程验证	55
5.1 引言	55
5.2 数据获取	55
5.3 基于 LiDAR 点云的桥墩建模	56
5.4 点云强度图和光学图片配准	56
5.5 裂缝识别与量化	59
5.6 结果展示	60
5.7 本章小结	62
6 结论与展望	63
6.1 结论	63
6.2 展望	64
参考文献	65

ABSTRACT

Since the Reform and Opening-up, bridge construction in China has entered a stage of "emphasis on both construction and maintenance." With the increase in the number of bridges and their extended service life, disease detection and maintenance management have become particularly important. Bridge piers are crucial structures, and developing efficient and accurate methods for detecting pier diseases is significant for the management of the entire lifecycle of bridges. Cracks are common issues in concrete bridge piers, and traditional manual visual inspections are inefficient, making it difficult to accurately quantify cracks and meet the demand for rapid quantitative analysis. Therefore, there is an urgent need to develop rapid 3D localization and quantification methods for pier cracks.

To address the above issues, this paper studies a 3D quantitative detection method for cracks in concrete bridge piers based on laser point clouds and image data, aiming to improve the accuracy of disease identification and quantification in bridges. The main research and findings are as follows: First, a reverse BIM construction method for three-dimensional modeling of bridge piers based on LiDAR point cloud data is proposed. Through point cloud acquisition, preprocessing, segmentation, and parameter extraction, parametric modeling methods for rectangular, circular, and round-end cross-section bridge piers are presented, and the impact of parameter errors is analyzed.

Secondly, a point cloud intensity image and optical image registration method based on the deep learning LoFTR algorithm is developed. The point cloud is converted into a feature-rich point cloud intensity image for registration. Optical images are stitched based on LoFTR to expand the image scene, increasing the number of features. LoFTR is used to register the point cloud intensity image and the optical image, and the outline feature in the point cloud intensity image is enhanced to improve registration accuracy. This ultimately establishes the correspondence between the point cloud and the optical image, thereby obtaining the resolution of the optical image and laying the foundation for the next step in disease recognition.

Finally, a crack recognition and quantification method is developed by incorporating CBAM into the backbone feature extraction network of the YOLOv8-seg model, resulting in the YOLOv8-CBAM-seg model, which is trained, validated, and tested on the SDNet2018 dataset. This model outperforms other methods such as U-Net and YOLOv8-seg in terms of precision (96.7%) and mAP@50 (94.9%). Additionally, a crack width quantization algorithm based on skeletal graphs is proposed, which includes crack crossing point removal based on morphology and crack skeleton pruning algorithms based on DFS. The DFS-based crack skeleton pruning algorithm does not rely on parameter specification and has a lower time

complexity compared to the DSE algorithm. In comparison with algorithms such as ESD and OB, the results of the EOB algorithm are more consistent with the orthogonal direction of the skeletal points, with an average relative error of -5.3% on datasets with fixed skeletal widths, demonstrating high quantization accuracy.

In experimental validation, reverse modeling of round-end cross-section bridge piers based on LiDAR point clouds resulted in extraction errors for cross-section parameters that were smaller than the accuracy of LiDAR, yielding satisfactory modeling results. In the point cloud intensity image and optical image registration phase, the deep learning-based LoFTR algorithm increased the number of feature points on low-texture surfaces, achieving nearly a 100% improvement in matching accuracy compared with traditional feature point extraction methods (e.g., SIFT and SURF). When enhancing outline features, the number of correctly matched points increased by 64% compared to the original LoFTR algorithm, confirming the effectiveness of the outline feature enhancement strategy. In terms of crack identification and quantification, the average relative error for simulated cracks on the front face of the bridge pier was 2.48%, with a standard deviation of 8.49%, while the average relative error for simulated cracks on the side face of the bridge pier was 11.74%, with a standard deviation of 13.57%. The quantization relative error for real cracks on the front of the bridge pier was -11.25%. The results indicate that the method presented in this paper demonstrates superior accuracy and stability on flat surfaces compared to curved surfaces, with the relative error in crack width quantization falling within an acceptable range, and it exhibits a high level of real-time processing capability. The paper also provides a three-dimensional display of cracks in the point cloud and establishes a comprehensive BIM model of the entire bridge for result demonstration.

In summary, the 3D quantitative detection method for cracks in concrete bridge piers based on laser point clouds and image data proposed in this paper holds significant theoretical significance and engineering application value in the field of bridge disease detection.

Key Words : Laser Point Clouds; Image Data; Bridge Damage; Three-Dimensional Detection; Deep Learning

1 绪论

1.1 研究背景与意义

改革开放以来,我国桥梁结构经过四十余年发展,已从大规模建设阶段进入“建养并重”阶段,需对桥梁全生命周期进行更加科学和精细的管理。桥墩是桥梁的重要结构,桥墩裂缝作为常见的表面病害,不仅影响了桥墩耐久性和承载力,还可能引发严重的安全事故。随着桥梁数量的不断增加,桥墩裂缝等病害已成为制约桥梁安全服役和运营的突出问题。目前,桥墩裂缝检测大多采用人工目视巡检等传统手段,其存在效率低、主观性强、裂缝难以精确量化等明显局限,难以应对桥梁下部结构的常态化巡检。此外,巡检数据分散、病害记录平面化,制约了进一步的病害分析和结构诊治。因此,针对桥墩裂缝开发快速三维定位和量化方法已成为当前桥梁运营与维护领域的重要课题。

随着遥感技术的不断成熟,激光雷达(LiDAR)作为一种高效、精确的三维数据获取手段,为桥梁的空间数字建模提供了全新手段。激光点云能够以毫米级精度采集桥梁全部结构表面的三维几何信息,不仅解决了缺乏基础资料的老桥自动建模难题,也极大提升了建模效率和模型精度。基于 LiDAR 点云的快速建模可自动提取桥梁主梁、桥墩、连接缝等重点部位的空间尺寸和构造细节,实现结构三维 BIM 模型的标准化与数字化,为后续裂缝的空间定位提供精确依托。

尽管 LiDAR 点云在桥梁结构建模和空间定位方面具有突出优势,但由于点云自身缺乏纹理和颜色等表观信息,难以对微小裂缝等表观病害进行精细化检测和量化。高分辨率光学照片则可以弥补这方面的不足。光学图像因其色彩丰富、纹理清晰、易于分析,广泛用于裂缝检测和表观病害识别。基于深度学习等算法,可以自动识别和分割图像中的各类裂缝并提取其长度、宽度等特征。然而仅靠光学图像不能准确反映桥梁结构病害在真实三维空间的精确位置和尺寸,难以进行空间建模和尺度量化。解决上述问题的突破口在于融合激光点云与高分辨率光学图像数据,形成数据互补、信息协同的三维量化检测方法。

总之,从桥梁裂缝检测的迫切需求出发,必须依托快速、精确的三维定位与量化手段。开发基于激光点云的桥梁 BIM 快速建模,并融合巡检图片针对裂缝等病害检测和量化的方法,有助于对运营期桥梁进行快速建模,对桥梁的服役状态进行全面、全生命周期管理的展示;有利于提升桥梁巡检的效率,降本增效,保障基础设施的安全,为智慧运维提供一定基础。

1.2 国内外相关研究工作进展

1.2.1 BIM 模型快速构建方法

运营期桥梁的桥墩 BIM 建模实质上是计算机视觉领域的三维重建问题。三维重建是建立适合计算机表示和处理的三维物体数学模型的过程，作为在计算机环境中处理、操作和分析物体性质的基础，也是构建虚拟现实的关键技术。根据采集设备是否主动发射测量信号，三维重建方法可分为基于被动视觉理论和基于主动视觉理论两类。

基于被动视觉理论的方法仅根据 RGB 二维图像的纹理分布等信息恢复深度信息，以实现三维重建，主要包括单目、双目和多目等方法。单目视觉只使用单一相机作为采集设备，具有低成本、易部署等优点，但其存在固有的问题：单张图像可能对应无数的真实物理世界场景，其解不是唯一的，故使用单目视觉方法实现三维重建的难度较大。双目视觉和多目视觉理论上可精确恢复深度信息，运动恢复结构（SFM）是其中的代表，其依赖于不同视角的图像来推断三维结构。谭浩^[1]提出了一种基于无人机倾斜摄影测量的真实场景三维重建方法，其重建模型的均方根误差（RMSE）在平面方向为 30mm，高程方向为 36mm，与 LiDAR 相比误差较大。此外，在实际测量中，SFM 方法受设备、天气、环境等因素的影响较大，如相机质量、飞行姿态、地理位置等，三维重建的精度无法得到保证^[2]。

基于主动视觉理论的方法可进一步分为基于 RGB-D 深度图的方法和基于点云的方法。其中，前者依靠 RGB-D 深度相机进行红外光测量，并基于 TOF 激光飞行时间法、结构光、三角测距法等来计算物体到相机的距离，得到单通道深度图。付晓凡^[3]使用 RGB-D 深度相机在大场景下进行快速旋转式三维地图构建，基本解决了快速性和精确度的问题，但仍受镜面物体干扰较大，点云较为稀疏，难以在现实中应用。由于红外光受室外光环境影响较大，该方法的主要应用场景位于室内，不能用于桥墩的点云采集。后者则依靠三维激光扫描仪来获得点云，其主要采用 LiDAR 进行测量，可分为地面和机载扫描等采集方式。地基激光雷达（TLS）可以对结构稀疏的特征点进行快速采样，从而对复杂结构进行测量，其广泛应用于土地测绘^[4]、林业资源调查^[5]等领域。近年来，随着无人机民用化技术的快速发展，无人机搭载 LiDAR 进行扫描成为一种可行的快速建模方法，与 TLS 相比，它具有不受树木等物体遮挡、不用架设多个测站，可以在高墩大跨桥的桥墩、桥塔等结构上应用等诸多优点。在实际的应用中，基于被动视觉理论的方法往往存在一定的畸变，TLS 则因设备移动产生的入射角差异^[6]而造成质量不高。随着我国交通基础设施向数字化建造方向发展，大量桥梁需要进行数字化模型构建。LiDAR 可以快速获取结构的高精度三维空间数据，用于建立基础设施的精准三维模型，

为基础设施信息化提供可靠的空间基础数据。因此，基于 LiDAR 点云快速构建 BIM 模型成为了研究的可行方向。

基于 LiDAR 点云对桥梁结构进行 BIM 构建主要可分为基于数据驱动和基于模型驱动等两种研究方法。基于数据驱动的研究方面，Xiong 等^[7]使用经典三维语义分割网络 PointNet 对点云进行分割，然后使用 Revit 插件 Dynamo 对提取出的点云轮廓进行参数化建模，生成与点云数据集相对应的 BIM 模型。Yan 等^[8]提出了一种嵌入高维几何特征的隐式建模框架 GEOP-Net，来对基于三维激光扫描的建筑物形状进行重建，以改善扫描点云的稀疏性和不完整性，其应对复杂度较高的屋顶时重建效果一般。Xia 等^[9]基于局部描述符和机器学习的方法，自动地从点云中提取桥梁构件，为从点云中构建 BIM 模型提供了效率更高的语义分割方法，但其数据集相对简单。Yan 等^[8]提出了一种基于分割结果的钢梁桥上部结构自动构建方法，以推进钢梁桥建模速度和精度，但其方法局限于特定的框架结构。Tang 等^[10]提出了一种基于深度学习和改进形态学的参数化建模方法，该方法可以自动生成几何和语义一致的室内空间 BIM 模型。基于数据驱动的研究可以实现更快速准确的应用，然而点云的数据量较大造成的大量运算资源消耗，以及目前桥梁结构的点云数据集较少等都限制了该方法的应用。

基于模型驱动的方法方面，Mehranfar 等^[11]提出一种基于空间几何关系和 2D 投影点云的桥梁主要构件自动重建方法，其重建的误差在 3cm 左右。Mafipour 等^[12]提出了参数化原型模型来辅助从分段点云中自动建立数字孪生的物理模型框架。赵馨怡等^[13]提出了一种基于 BIM 和三维激光扫描仪的建筑物施工质量检测方法，其主要通过测量点云导入 Revit 软件与设计 BIM 进行比对，从而对建筑物施工质量进行检测。Ma 等^[14]使用 Revit 等三种商业软件将 3D BIM 模型转化为点云，从而增加数据集的大小，来提高基于深度学习的语义分割网络的性能。Duan 等^[15]开发了基于欧氏聚类和网格分割算法来自动切片点云提取轮廓特征，使用 Dynamo-Revit 建模的框架生成数字孪生模型，其重建精度在毫米级。基于模型驱动的方法可以进行简单直观模型构建，可行性较高。该方法还存在一些亟待解决的问题：采集到的点云不均匀、稀疏，存在大量植被、车辆、行人等噪声。因此，需要进一步对 LiDAR 点云进行降噪、分割等操作，进行参数化建模，为病害的展示奠定基础。

1.2.2 裂缝识别和量化方法

目前，裂缝识别主要依赖人工目视检查的方法，这些方法速度慢且裂缝难以被量化，难以满足对混凝土结构进行精确检查的需求^[16]。因此，急需开发一种快速的裂缝识别和量化的方法。基于混凝土图像的裂缝识别是一种可行的办法，其具有数据采集成本低、可视化、可解释性强的优点。数字图像处理(DIP)算法被用于裂缝分割，如边缘检测^[17-20]、

阈值分割^[21]、形态处理^[22]、纹理分析^[23, 24]和模板匹配^[25]，这些方法计算效率高且易于解释，但在光线较差等背景复杂的条件下表现较差。随着人工智能（AI）的飞速发展，基于深度学习的图像处理方法大量出现。这些方法能够准确识别混凝土裂缝，并具有强大的泛化能力。在裂缝识别方面，Zheng 等^[26]引入了基于区域的全卷积网络（FCN）模型，在建筑裂缝特征提取中实现了 80.44% 的像素准确率。Zhang 等^[27]提出了一种频域处理算法，结合卷积神经网络（CNN）和长短期记忆网络（LSTM），在桥面裂缝检测中实现了 99.25% 的准确率。Tran 等^[28]比较了 YOLOv7 与 Faster R-CNN 和 RetinaNet 在桥面裂缝检测中的表现，结果表明 YOLOv7 的准确性更高、速度更快。处理语义分割或实例分割任务的算法可以实现像素级的分割，进而识别裂缝等缺陷区域。Wang 等^[29]引入了 SegCrack 模型，在建筑裂缝数据集上实现了 96.66% 的像素级分割精度。Shi 等^[30]评估了四种最先进的语义分割模型在建筑材料裂缝识别中的表现，发现 U-Net 与 SENet 结合的效果最佳，达到了 84.5% 的精度。Liu 等^[31]开发了一种基于 Mask R-CNN 的实例分割模型，在混凝土裂缝检测中实现了 98.8% 的精度和 78.0% 的召回率。为了提升目标检测的准确率和速度，卷积块注意力模块（CBAM）^[32]已被应用于 YOLO 模型中。Wang 等^[33]基于 YOLOv8 模型的框架提出了 CBAM-YOLOv8 模型，用于检测 GPR 图像中的病害。Zhang 等^[34]将 CBAM 与 YOLOv8 结合，用于隧道的病害检测，使用 U-Net 模型进行语义分割。尽管这些方法在裂缝检测中取得了较高的准确率，但尚未实现裂缝的量化。

裂缝的量化即提取裂缝的宽度和长度等参数。在各种方法中，基于裂缝骨架的裂缝量化因其高准确性和清晰的定义而被广泛使用，其更接近于裂缝的手动测量。裂缝骨架是表示裂缝跨度的基本结构，可以使用中轴变换（MAT）算法^[35]或 Zhang-Suen 算法^[36]进行计算。裂缝的长度可以通过裂缝骨架点的像素数量^[37]或像素距离的总和^[38, 39]来确定，而裂缝的宽度量化的关键在于裂缝骨架点上的宽度定义。

值得注意的是，基于单张图像的裂缝量化方法只能获得像素级的裂缝信息。为了获取裂缝的实际大小，一种方法是使用标定板。Kim 等^[40]在桥墩上放置固定大小的平面标记，使拍摄的图像包含已知尺寸的几何形状，从而能够计算出像素的大小。这种方法的准确性较高，但其效率较低，且难以对曲面上的裂缝进行量化。另一种方法是基于图像的三维重建，它使用多张图像恢复物体的三维信息，从而能够测量实际的裂缝大小。Liu 等^[41]采用了一种基于图像的三维重建方法来评估桥墩裂缝，其精度可达 mm 级。该方法包括将裂缝投影到网格化的三维表面三角模型上，以减少在非平坦结构表面量化裂缝时的误差。这种方法的结果较为精准，但其需要大量计算，在小规模低曲率的场景中对裂缝量化准确性的改善有限。Woo 等^[42]和 Yu 等^[43]采用类似的方法检测和评估地震后建筑外立面的裂缝和剥落。然而，三维重建方法依赖图像特征来进行图像间的匹配，这需要

图像间的重叠率大于 50%^[41], 这就需要收集大量的图片。除此之外, 低质量的图像或不恰当的采集方法可能导致图像的失真, 直接影响了裂缝量化的准确性。

与基于图像的方法相比, LiDAR 可以获取包含目标物体三维坐标和反射强度等信息的点云, 许多专家学者基于 LiDAR 开展了裂缝量化的研究。Jiang 等^[44]和 Wu 等^[45]采用地面激光扫描 (TLS) 获取点云以提取墙壁裂缝的宽度, 其检测精度达到了厘米级。Cabaleiro 等^[46]提出了一种利用点云检测和分析木梁裂缝的方法, 基于高精度的点云数据, 其检测精度达到了厘米级。为减少运算量, 这些研究都将 3D 点云转化成点云强度图进一步处理。架站式扫描仪精度较高, 但其数据收集的效率较低, 涉及的方法也较为复杂。移动扫描仪数据采集效率较高, 却缺乏进行厘米级检查所需的精度。因此, 仅基于点云对混凝土裂缝进行量化仍然具有挑战性。这些方法都未能实现对混凝土裂缝实际大小的快速准确量化, 且很少考虑位于非平面表面的裂缝。

结合高分辨率光学照片和 LiDAR 点云的优势, 有助于裂缝准确的识别和量化。光学图像具有可读性高、色彩和纹理丰富的特点, 易于裂缝的精确识别, 而采集成本高但信息丰富的 LiDAR 点云则可以提供准确的定位和三维信息。这两个模态的融合减少了硬件复杂性并降低了成本, 使其成为值得探索的研究方向。在这样的背景下, Awad^[47]将光学照片与 LiDAR 点云融合, 通过最小化过度分割来增强遥感图像中的城市特征的提取。在这项研究中, 光学图片提供了丰富的纹理和颜色细节, 而 LiDAR 点云则提供了高度和强度信息, 两项数据源是通过建立地面控制点来进行配准的。与该研究类似的是, Elamin 等^[48]通过将低成本 LiDAR 数据与无人机 (UAV) 捕获的图像结合, 改善了道路裂缝分割的效果。他们的方法依赖于 Peng 等^[49]提出的图像配准方法, 但该方法局限于城市环境。Xu 等^[50]利用 Zernike 矩将图像与点云配准, 而无需位置和方向系统, 从而实现建筑点云的着色。这项技术促进了点云强度图像与整个建筑立面的光学图像的融合。因此, 亟需开发融合的光学图片和 LiDAR 数据的三维裂缝量化方法。

1.3 论文研究思路及目标

1.3.1 主要研究内容

本文旨在探究基于激光点云和图像数据的桥墩裂缝三维检测方法, 为此, 本文主要在以下几个方面开展研究:

(1) 基于 LiDAR 点云的桥墩三维建模方法。本文提出了 LiDAR 点云数据的采集与预处理方法, 包括噪声去除、点云配准等; 探讨了基于点云的 BIM 模型构建方法, 分别以矩形截面、圆形截面和圆端形截面为例, 进行了截面参数提取和族参数化建模研究, 并对误差进行了分析。

(2) 点云强度图和光学图片配准方法。本文提出了点云强度图生成方法，通过投影法和特征增强提升点云强度图的纹理信息；开发了基于深度学习 LoFTR 算法的点云强度图与光学图片配准方法，建立点云与图片之间的像素对应关系，为病害识别奠定基础。

(3) 裂缝识别与量化方法。本文提出了基于 YOLOv8-seg-CBAM 模型的裂缝实例分割方法，提出了裂缝宽度量化 EOB 算法，包括基于形态学操作的裂缝交叉点去除算法和基于 DFS 的裂缝骨架剪枝算法，结合图像分辨率实现裂缝宽度的量化。

(4) 工程验证。本文探讨了基于点云和图像数据的混凝土桥墩裂缝三维定量检测方法在实际工程中的应用，验证了方法的可行性和有效性。

1.3.2 技术路线图

本文技术路线图如图 1.1 所示：




图 1.1 技术路线图

Fig. 1.1 Technology road-map

2 基于 LiDAR 点云的桥墩三维建模方法

2.1 引言

本章探讨了基于 LiDAR 点云数据构建桥墩 BIM 模型的方法。LiDAR 能够快速获取结构的三维坐标和反射率信息，帮助识别和记录结构的实际状态，为后续维护和加固提供数据支持。桥墩作为桥梁的重要组成部分，其设计和状态直接影响桥梁的安全性。通过对桥墩点云数据进行建模，可以捕捉关键构件的几何特征，为其他构件的建模提供参考，从而为建立全桥的 BIM 模型奠定基础。

因此，本章介绍了 LiDAR 采集点云的原理和 LiDAR 点云预处理方法；针对不同的截面形状，本章提出了桥墩的 BIM 模型构建方法，并分析了参数的误差影响。

2.2 LiDAR 点云采集

如图 2.1 所示，LiDAR 采集点云的基本原理是：通过激光发射器发射短脉冲激光光束，这些激光脉冲以光速传播并照射周围环境。当激光光束遇到物体表面时，会反射回激光雷达系统，反射的强度和速度取决于物体的材质、颜色和表面特性。激光雷达的接收器捕捉反射光束，并记录激光发射与接收之间的时间差（ToF）。LiDAR 通常配备惯性测量单元（IMU）和全球定位系统（GPS），以获取其空间位置和姿态。结合距离和位置信息，可以将每个测量点转换为三维坐标。通过多次激光脉冲测量，LiDAR 系统生成包含大量三维坐标的点云数据集，其可以表示环境的形状和特征。





图 2.1 LiDAR 采集点云原理

Fig. 2.1 Principle of LiDAR point cloud acquisition

实时定位与地图构建技术（SLAM）是一种在未知环境中自我定位的同时构建环境地图的技术。LiDAR 与 SLAM 的结合，可以显著减少因信号干扰或多路径效应导致的定位误差；在室内或复杂环境，SLAM 同样可以弥补 GPS 信号不足带来的定位困难问题。因此，本文使用的 LiDAR 设备为 GoSLAM RS100S 移动测量系统，其扫描的最大

距离为 120m, 拥有 $360^{\circ} \times 285^{\circ}$ 的范围, 扫描速度为 32 万点/秒, 精度可达 1cm, 如图 2.2 (a) 和 (b) 所示, 其支持手持式和无人机载 (搭载于 DJI M350) 等两种采集方式。



(a) (b)
图 2.2 LiDAR 搭载方式: (a) 手持式 (b) 机载式

Fig. 2.2 LiDAR mounting methods: (a) Handheld (b) Airborne

手持式采集方式是一种灵活且有效的方法, 尤其适用于空间受限的区域。手持设备可以在复杂环境中灵活移动, 便于对结构物的特定部位进行详细采集。这种方法能够在关键位置减慢移动速度, 以增加数据量并丰富点云的细节, 从而提高数据的质量和准确性。另一方面, 机载扫描技术则适用于高度超过 30 米的结构物。无人机搭载高精度的激光扫描仪或摄影设备, 能够在高空进行灵活飞行, 实现对结构物的高效、全面的数据采集。通过控制飞行速度和飞行距离, 机载扫描可以提高数据的采集密度, 确保点云数据的清晰度和完整性。结合手持和机载方式, 可以在不同的环境和条件下灵活选择最合适的数据采集方法, 从而建立起完整的三维模型, 为后续的分析、监测和维护提供可靠的数据支持。

2.3 LiDAR 点云预处理

2.3.1 CloudCompare 软件

从理论上讲, LiDAR 采集的点云数据应具有均匀性、平滑性和完整性。然而, 在工程实践中, 由于桥梁等结构通常处于复杂环境中, 点云数据往往受到车辆、行人、植被等因素的干扰, 导致噪声、冗余点及数据不完整等问题的出现。在完成点云数据的现场采集后, 为了全面描述桥梁结构, 通常需要从多个角度采集点云数据, 并对其进行进一步处理, 以去除噪声并构建完整的点云模型。因此, 在 LiDAR 获得点云后, 需要使用相匹配的点云数据处理软件对采集到的点云进行预处理。常用的点云数据处理软件包括

Terrasolid、Cyclone、Realworks、GoSLAM studio、CloudCompare 等,由于以 CloudCompare 为代表的开源软件对各种点云数据类型的兼容性较好,本文采用 CloudCompare 点云处理软件进行 LiDAR 点云预处理。

CloudCompare 软件界面如图 2.3 所示。CloudCompare 是一款开源的 3D 点云处理软件,由 Daniel 博士于 2009 年开发并公布在其个人主页上,至今仍在更新维护,其广泛应用于地理信息系统(GIS)、建筑、工程和科学研究等领域。它支持多种点云数据格式,能够进行点云的可视化、分析和处理。




图 2.3 CloudCompare 软件界面
Fig. 2.3 CloudCompare software interface

本文采用开源软件 CloudCompare 进行点云数据处理,其流程如图 2.4 所示,主要包括以下三个步骤:




图 2.4 点云预处理
Fig. 2.4 Point cloud preprocessing

2.3.2 噪声去除

首先,将桥墩的原始点云数据导入 CloudCompare。由于 LiDAR 的扫描范围较大,点云数据中通常包含目标结构以外的部分(如地面等环境噪声)。因此,需利用“分段”功能去除明显的环境噪声。随后, LiDAR 在地面采集桥墩点云时,扫描距离和扫描角度的不同会导致点云密度不均匀,需要对点云进行降采样处理方法,使点云密度保持一致,

其常用的降采样方法包括随机采样、空间采样、八叉树法^[51]等。本文采用基于空间网格的空间子采样（Spatial Sub-sampling）进行降采样。该方法通过将点云划分为固定大小的三维网格（体素），然后在每个网格中选择一个代表点（通常是网格中心点或网格内的随机点），进而均匀地减少点云密度，同时保留点云的整体几何结构。在 CloudCompare 中使用“二次采样”功能，选择“空间”方法进行降采样，合理设置网格大小。

最后，对于点云中存在的离群点、漂移点、冗余点和折射点等噪声点有必要进行降噪处理，以提升点云的质量、减少数据冗余，从而为后续的点云处理打好基础。常见的点云滤波方法包括 SOR 滤波、统计滤波等。统计滤波器能有效去除离群点，且适用于密度不均匀的点云，因此，本文采用统计滤波器去除点云噪声。统计滤波器通过计算每个点在其邻域内的平均距离，删除距离平均值大于设定的阈值（邻域大小和标准差倍数）的点。在 CloudCompare 中使用“清理”功能，选择“噪声滤除”方法进行统计滤波，合理设置阈值，从而实现最佳的去噪效果。

噪声去除方法的效果如图 2.5 所示。原始点云数据经过分段操作，去除了地面和横梁点云，保留了桥墩结构点云；通过空间方法的二次采样（最小点距离为 0.01m），结构点云点的数量从 196926 个降到 117141 个，保留点云的结构同时，使点云更加均匀；通过统计滤波器去噪（KNN 点的数量为 5，阈值为 1 倍标准差），结构点云点的数量减少至 79924 个，且减少了噪声点的数量（图中黑框所示），为后续的点云处理打好了基础。




图 2.5 噪声去除

Fig. 2.5 Noise removal

2.3.3 点云配准

点云配准的原理如图 2.6 所示，图中蓝色线条为源点云，红色线条为目标点云，配准过程分为粗略配准和详细配准。首先对点云进行粗略配准。在桥梁点云配准过程中，首先需要对两站点云数据进行初步对齐，即粗略配准。这是由于桥梁点云数据量通常较大（一次采集数据量 1 个 G 以上），存在显著的空间位置差异；且由于桥梁结构的复杂性，点云特征难以被准确捕捉，自动配准算法（如迭代最近点 ICP 算法）容易陷入局部最优解，难以直接完成配准。因此，在完成点云噪声去除后，利用 CloudCompare 的“对齐”功能，选定一个点云作为参考点云，另一个点云则为待对齐点云，通过手动选择两个点云中的等效点对（大于 3 对），进行待对齐点云的三维旋转和平移操作，使其与参考点云尽量重合。




图 2.6 点云配准原理图

Fig. 2.6 Point cloud registration schematic

在粗略配准的基础上，本文进一步采用 ICP 算法^[52]对点云进行精细配准。ICP 算法通过迭代调整点云之间的位置和姿态，逐步优化源点云 P 和目标点云 Q 的重叠程度，其基本流程如下：

- (1) 使用最邻近搜索算法，对于源点云 P 中每个点，找到目标点云 Q 距离最近的点，形成点对集合。
- (2) 使用最小二乘法，根据匹配的点对集合，计算一个刚体变换（旋转矩阵 R 和平移向量 t ），使得源点云 P 在变换后与目标点云 Q 的误差值最小。
- (3) 将计算得到的刚体变换应用到源点云 P 上，计算源点云 P 和目标点云 Q 之间的配准误差（欧氏距离的均值）。
- (4) 如果配准误差小于设定的阈值，或达到最大迭代次数，则停止迭代，否则重复步骤 1—3，直到满足条件。

如图 2.7 所示，在 CloudCompare 中精细配准的具体操作包括选择“配准”功能，应用 ICP 算法，并根据实际需求调整参数（最大迭代次数和收敛精度），以获得更高精度的配准结果。当所有点云数据完成配准后，CloudCompare 会自动处理重叠区域，消

除重复点，并将其融合为一个完整的点云模型。




图 2.7 点云配准

Fig. 2.7 Point cloud registration

2.4 BIM 模型构建

2.4.1 桥墩截面类型及其 BIM 模型构建方法

如图 2.8 所示，桥墩通常由墩帽、墩身、基础三部分组成。墩帽上常常放置支撑桥跨结构的支座；墩身则上接墩帽，下接基础；基础则连接墩身并坐落在岩石或土等地基上。桥墩从整体上可以分为两大类，即重力式桥墩和轻型桥墩。重力式桥墩即实体式桥墩，在承受外力时，依靠自身和作用其上的重力获得稳定的桥墩，其按照墩身的截面形状可以分为矩形墩、圆形墩、圆端形墩、尖端形墩等。轻型桥墩则是指因减小地基负荷、增大桥下净空、加快施工进度、增加美观程度等原因减小墩身尺寸、降低桥墩自重，并允许受力后在一定范围内弹性变形的桥墩。轻型桥墩的主要形式包括柱式桥墩、板式桥墩、空心薄壁墩、框架墩等，其墩身的截面形状同样包括矩形墩、圆形墩和圆端形墩等^[53]。




图 2.8 桥墩示意图

Fig. 2.8 Schematic diagram of bridge pier

针对圆形、圆端形、矩形等墩身截面形状，本文提出了桥墩 BIM 模型构建方法，其主要包括以下三个步骤：

(1) 构件点云分割。在获得桥梁的 LiDAR 点云后，需要分割出目标构件的点云。对于桥墩构件，点云分割可以通过人工处理单次扫描数据，或使用随机采样一致性（RANSAC）算法提取柱状结构，其步骤如下：

1) 直通滤波：通过设定最小值和最大值，来过滤掉不在特定范围内的点，可以有效去除噪声值和异常值。假设点云 P 中的每个点由三维坐标 (x_i, y_i, z_i) 表示，由下式对 Z 轴这一维度进行直通滤波：

$$z_{\min} \leq z_i \leq z_{\max} \quad (2.1)$$

其中， $z_{\min}$ 和 $z_{\max}$ 分别为设定的最大值和最小值。

2) 法线估计：法线是描述点云中每个点周围表面方向的向量。法线估计可以识别和提取表面特征，为下一步点云到模型的距离计算提供了方向。对于点云 P 中的每个点 P_i ，选择其邻域内的点 $\{P_j\}(j \neq i)$ ，通过距离度量（如欧氏距离）来确定邻域，常用的半径 r 或固定数量的邻域点 k ：

$$N_i = \{P_j | \|P_i - P_j\| \leq r\} \quad (2.2)$$

$$N_i = \{P_j | j \text{ 是 } P_i \text{ 的前 } k \text{ 个邻域点}\} \quad (2.3)$$

通过对协方差矩阵进行特征值分解，获取特征向量和特征值。法线向量 N_i 取协方差矩阵 C 对应最小特征值的特征向量：

$$C \cdot v = \lambda v \quad (2.4)$$

选择特征值最小的特征向量 $v_{\min}$ ，得到法线向量：

$$N_i \propto v_{\min} \quad (2.5)$$

由于法线有两个方向（指向内外），可以通过计算点 P_i 到邻域点的偏差来确保法线方向一致性。通常选择法线方向指向外部（相对于点云的整体形状）。法线估计完成后，每个点 P_i 的法线可以表示为：

$$N(P_i) = \begin{pmatrix} N_x \\ N_y \\ N_z \end{pmatrix} \quad (2.6)$$

3) RANSAC 算法拟合：RANSAC 算法是一种鲁棒性强的参数估计方法，广泛应用于点云数据处理和模型拟合。对于给定的点云集 $D = \{P_i | 1 \leq i \leq n\}$ 以及一个误差阈值 ϵ ，从数据集 D 中随机选择 3 个点，形成点的子集 $S \subset D$ 。使用子集 S 估计模型参数 θ ，并假设要拟合的模型为函数 $f(P, \theta)$ 。对于数据集中的每个点 P_i ，计算其到模型的距离：

$$d_i = \| P_i - f(P, \theta) \| \quad (2.7)$$

根据误差阈值 ϵ 将点分类为内点 ($d_i \leq \epsilon$) 和外点 ($d_i > \epsilon$)，定义点的集合为：

$$I = \{P_i \in D | d_i \leq \epsilon\} \quad (2.8)$$

则内点的数量为 $|I|$ 。重复上述步骤 N 次，选取具有最多内点数量的模型作为最佳模型。RANSAC 算法能够有效地处理含有噪声和异常值的数据，确保最终得到的模型具有较高的准确性和可靠性。通过以上步骤，即可确定柱状结构的点云和参数，即完成构件点云的分割。

(2) 构件参数提取。在获得桥墩构件的点云后，需要对其进一步分析和处理，以提取其几何特征和相关参数，即桥墩的高度和截面形状参数。


1) 桥墩高度：桥墩的高度 h_p 可以通过桥墩点云坐标 z 值的极值来确定^[6]：

$$h_p = z_{\max} - z_{\min} \quad (2.9)$$

2) 截面参数：对于步骤 1 获取的桥墩点云，通过指定点坐标的 z 值，来对桥墩进行切片以获取截面。为确保截面点的质量，根据点云的精度设定一定的厚度 t （大于点云的密度 ρ ）来进行 $(z - 0.5 * t, z + 0.5 * t)$ 范围的切片。对于获取到的截面点云，根据截面形状类型确定其参数，如表 2.1 所示，这部分将在后续小节详细介绍。

表 2.1 桥墩截面的参数

Tab. 2.1 Parameters of the bridge pier cross-section

截面形状	参数
矩形 	1) 截面长度 2) 截面宽度
圆形 	1) 圆的半径
圆端形 	1) 半圆端半径 2) 半圆端中心距

(3) 族的参数化创建。在完成构件的点云分割和参数提取后，本文基于 LiDAR 点云和 Revit 进行 BIM 模型构建。Revit 是一款由 Autodesk 开发的 BIM 软件，旨在支持建筑设计、施工和运营的各个阶段。它允许用户创建三维建筑模型，并在此基础上生成二维图纸、详细信息和材料清单。Revit 是我国建筑业 BIM 体系中使用最广的软件之一。

在 Revit 中，族是项目的基本元素。族是指一组具有相似特征和行为的元素，可以在项目中重复使用。族的参数化创建使得在不同的工程实际中，根据 LiDAR 点云数据参数提取结果设置参数，来快速构建构件和结构的模型。Revit 自身提供了丰富的族库，包括系统族、可载入族和内建族。系统族主要是为建筑服务行业的需求而设计的，支持直接载入使用。在桥墩 BIM 模型构建中，系统族并不适用，需要构建可载入族，从而适应于构建过程，并提升建模效率。

可载入族的创建流程如图 2.9 所示，其中，桥墩的族样板选择为 Revit 自带的“公制常规模型”。在接下来的小节中，本文对圆形、圆端形、矩形和尖端形四种桥墩截面形状进行了 BIM 模型的构建，并讨论了相关误差。




图 2.9 桥墩构件创建流程图

Fig. 2.9 Bridge pier component creation flow chart

2.4.2 矩形截面桥墩的 BIM 构建

本文以西打马井沟 3 号大桥④号桥墩为例，对矩形截面桥墩 BIM 模型的构建进行讨论。西打马井沟 3 号大桥位于宁夏中部青铜峡市境内。该桥跨径布置为 $(4 \times 40) + (3 \times 40)$ m，桥梁全长 289m，下部结构采用薄壁空心墩和柱式墩，其中主桥④号桥墩最高，可达 64.6m，采用等截面矩形薄壁空心墩，横桥向宽度 5m，顺桥向宽度为 3.5m。墩身混凝土采用 C40，现场照片如图 2.10 中红框所示。




图 2.10 现场照片（矩形截面）

Fig. 2.10 Site photo (rectangle cross-section)

矩形截面桥墩 BIM 模型的构建包含下列步骤：

(1) 桥墩点云分割：采用 RANSAC 算法分割出桥墩点云。

(2) 点云参数提取：对于步骤 (1) 获取的桥墩点云，进行切片处理。对于点云切片，采用下列算法计算其参数：

1) 噪声去除：使用统计滤波器去除噪声，以避免噪声干扰切片边界的提取。

2) 平面提取：对点云进行平面分割以得到计算边界的平面，进一步去除噪声。

3) 边界计算：使用 Open3D 库从平面内点云中基于 α 形状理论建立三角网格，以有效地捕捉点云的形状，该步骤通过参数 α 来控制边界的细致程度。较小的 α 可以生成更加细致的边界，较大的 α 可以生成更加平滑的边界。从三角网格中提取非流形边，即不符合流形性质的边，通常表示网格的边界，这些网格的边界点即视为点云的边界点。

4) 凸包计算：将三维边界点投影到 XoY 平面，并计算这些投影点的凸包，其中，凸包可用于描述点集的外部边界，常用于形状分析、物体识别等应用。

5) 使用 K-means 聚类方法将凸包点聚类成四个点，其聚类中心即为四边形的顶点。

对于厚度 $t = 0.4 \text{ m}$ 的点云切片（图 2.11 中蓝色点），采用 $\alpha = 0.04$ 计算其边界点如图 2.11 中红色点所示，其凸包极值点如图 2.11 中绿色点所示，并将其连线（绿色线条）。可以看出，本文提出的方法很好地提取出了矩形截面的四个顶点。




图 2.11 矩形截面的参数提取

Fig. 2.11 Parameter extraction of rectangle cross-section

(3) 族参数化创建：打开 Revit 软件，点击“文件”选项卡，新建一个族，打开“公制常规模型”族样板文件 (*.rft)。在“创建”选项卡“属性”面板打开“族类型”界

面, 创建族参数的“名称”、规程、参数类型、参数分组类型, 如图 2.12 所示。对于桥墩材质参数的值, 打开材质浏览器后, 新建命名为“桥墩材质”的材料, 并根据工程实际添加基本热量、机械、混凝土等物理性质。在参照标高视图拉伸创建矩形, 对矩形的长和宽进行“对齐尺寸标注”, 通过鼠标右键选择“标签”命令, 分别设置为“截面长度 B”和“截面宽度 A”。点击矩形, 在属性面板中将拉伸的终点关联至“墩顶高程”参数, 将拉伸的起点关联至“墩底高程”参数, 得到桥墩模型如图 2.13 (a) 所示。

参数	值	公式	锁定
文字			
桥墩编号(默认)	0	=	☐
材质和装饰			
桥墩材质(默认)	混凝土, 预制	=	☐
尺寸标注			
墩底高程(默认)	0.0000 m	=	☐
墩顶高程(默认)	70.4800 m	=	☐
截面宽度A(默认)	3.5200 m	=	☐
截面长度B(默认)	5.0300 m	=	☐

图 2.12 桥墩族参数 (矩形截面)

Fig. 2.12 Pier family parameters (rectangle cross-section)




图 2.13 桥墩族模型 (矩形截面): (a) 模型 (b) 叠加点云和模型

Fig. 2.13 Pier family model (rectangle cross-section): (a) Model (b) Overlay point cloud and model

(4) 构建效果验证: 为验证构建的桥墩 BIM 模型与其点云之间的原始坐标匹配和效果, 将构建的桥墩模型 (.rfa) 转换为模型文件 (.ply), 并在 Cloudcompare 软件中同时打开点云和模型文件 (.ply)。如图 2.13 (b) 所示, 点云和模型分别为蓝色和绿色, 可以看出, 点云和模型没有完全重合, 这是由于桥墩点云的建模参数来自于拟合, 桥墩侧面点云的轻微凹凸是难以避免的。从正面和顶部的视角看, 桥墩的重叠效应相当大。综合整体和局部的检查, 基于点云构建的桥墩 BIM 模型与点云几乎完全重合。

桥墩点云建模的关键是截面参数提取, 因此, 对 α 和 t 进行了误差分析, 其结果如表 2.2 和表 2.3 所示。可以看出, 随着 α 的增大, 截面宽度和长度的绝对误差均变大, 这是因为 α 的增大导致点云拟合轮廓更加光滑, 因此得到了截面参数较大的估计; 当 t 较小时, 截面宽度和长度的绝对误差较小, 这是由于点云具有稀疏性, 当点云厚度过小时, 会导致部分轮廓缺失, 因此得到了截面参数较小的估计, 当 t 较大时, 点云的噪声投影到一个平面上, 得到截面参数较大的估计。

表 2.2 参数 α 误差分析Tab. 2.2 Error analysis of α

参数 α	截面宽度/m	截面宽度绝对误差/m	截面长度/m	截面长度绝对误差/m
0.02	3.45	-0.05	4.92	-0.08
0.04	3.52	0.02	5.03	0.03
0.06	3.57	0.07	5.10	0.10
0.08	3.59	0.09	5.10	0.10
0.10	3.65	0.15	5.16	0.16

表 2.3 参数 t 误差分析Tab. 2.3 Error analysis of t

参数 t/m	截面宽度/m	截面宽度绝对误差/m	截面长度/m	截面长度绝对误差/m
0.10	3.45	-0.05	4.95	-0.05
0.20	3.47	-0.03	4.99	-0.01
0.40	3.52	0.02	5.03	0.03
0.60	3.60	0.10	5.10	0.10

2.4.3 圆形截面桥墩的 BIM 构建

本文以大连理工大学某建筑混凝土外立柱为例，模拟圆形截面桥墩，对 BIM 模型构建进行讨论，该立柱高约 15.7m，现场照片如图 2.14 中红框所示。



图 2.14 现场照片（圆形截面）

Fig. 2.14 Site photo (circle cross-section)

圆形截面桥墩 BIM 模型的构建包含下列步骤：

- (1) 桥墩点云分割：采用 RANSAC 算法分割出桥墩点云。
- (2) 点云参数提取：对于步骤 (1) 获取的桥墩点云，进行切片处理。对于点云切片，采取下列算法计算其参数：
 - 1) 噪声去除：使用统计滤波器去除噪声，以避免噪声干扰切片边界的提取。
 - 2) 半径计算：使用 PCD 库中的 `get_center()` 方法对点云的质心点 (C_x, C_y, C_z) ，进行提取，并通过下式计算其截面半径 r_c ：

$$d_i = \sqrt{(x_i - C_x)^2 + (y_i - C_y)^2 + (z_i - C_z)^2} \quad (2.10)$$

$$r_c = \frac{1}{N} \sum_{i=1}^N d_i \quad (2.11)$$

当桥墩截面点云不太规整时，采用最小二乘法来拟合圆心和半径。最小二乘法是数据分析和机器视觉等领域常用的算法，其通过最小化点到拟合圆的距离平方和，提供了一种有效的方式来估计圆的参数。本文首先通过最小二乘法拟合平面，再将点投影到平面上，最后在平面内拟合圆，最终按 (2.10) 和 (2.11) 的公式计算圆心和半径。

对于厚度 $t = 0.2 \text{ m}$ 的点云切片，计算其半径 $r_c = 0.434 \text{ m}$ ，与点云中的测量结果相同，如图 2.15 所示。可以看出，最小二乘法对圆形截面点云的半径拟合效果良好。




图 2.15 圆形截面的参数提取

Fig. 2.15 Parameter extraction of circle cross-section

(3) 族参数化创建：点击“文件”选项卡，新建一个族，打开“公制常规模型”族样板文件 (*.rft)。在“创建”选项卡“属性”面板打开“族类型”界面，创建族参数的“名称”、规程、参数类型、参数分组类型，见图 2.16。

参数	值	公式	锁定
文字			
桥柱编号	0	=	☐
材质和装饰			
桥柱材质	桥柱材质	=	☐
尺寸标注			
坡度	0.00°	=	☐
柱底高程	0.0000 m	=	☐
柱径	0.4340 m	=	☐
柱顶高程	15.6960 m	=	☐

图 2.16 桥墩族参数（圆形截面）

Fig. 2.16 Pier family parameters (circular cross-section)

对于桥墩材质参数的值，打开材质浏览器后，新建命名为“桥墩材质”的材料，并根据工程实际添加基本热量、机械、混凝土等物理性质。在参照标高视图拉伸创建圆形，对圆形的半径进行“半径尺寸标注”，通过鼠标右键选择“标签”命令，设置为“柱径”。点击圆形，在属性面板中将拉伸的终点关联至“墩顶高程”参数，将拉伸的起点关联至“墩底高程”参数，完成了族的参数化创建，如图 2.17（a）所示。




图 2.17 桥墩族模型（圆形截面）：（a）模型（b）叠加点云和模型

Fig. 2.17 Pier family model (circular cross-section): (a) Model (b) Overlay point cloud and model

(4) 构建效果验证：为验证构建的桥墩 BIM 模型与其点云之间的原始坐标匹配和效果，将构建的桥墩模型（.rfa）转换为模型文件（.ply），并在 Cloudcompare 软件中同时打开点云和模型文件（.ply）。如图 2.17（b）所示，点云和模型分别为灰色和绿色，可以看出，点云和模型没有完全重合，这是由于桥墩点云的建模参数来自于拟合，因此，桥墩侧面点云的轻微凹凸是难以避免的。从正面和顶部的视角看，桥墩的重叠效应相当大。综合整体和局部的检查，基于点云构建的桥墩 BIM 模型与点云几乎完全重合。

桥墩点云建模的关键是截面参数提取，因此，对 t 进行了误差分析，其结果如表 2.4 所示，其结论与矩形截面参数提取相似。

表 2.4 参数 t 误差分析Tab. 2.4 Error analysis of t

参数 t/m	截面半径/m	截面半径绝对误差/m
0.10	0.418	-0.016
0.20	0.434	0
0.40	0.455	0.21

2.4.4 圆端形截面桥墩的 BIM 构建

本文以大连理工大学某变截面人行桥桥墩为例，对圆端形截面桥墩的 BIM 模型构建进行讨论，该桥墩高 7m，截面为变截面圆端形，其现场图片如图 2.18 所示。



图 2.18 现场照片（圆端形截面）

Fig. 2.18 Site photo (round end cross-section)

圆端形截面桥墩 BIM 模型的构建包含下列步骤：

- (1) 桥墩点云分割：采用 RANSAC 算法分割出桥墩点云。
- (2) 点云参数提取：对于步骤 (1) 获取的桥墩点云，进行切片处理。对于点云切片，采取下列算法计算其参数：

- 1) 噪声去除：使用统计滤波器去除噪声，以避免噪声干扰切片边界的提取。

- 2) 包围盒计算：点云包围盒是一种求解离散点集最优包围空间的算法，其基本思想是用体积稍大且特性简单的几何体（包围盒）来近似地代替复杂的几何对象。常见的包围盒算法有轴对齐包围盒（AABB）和方向包围盒（OBB）。AABB 在三维空间中是一个简单的六面体，每一边都平行于一个坐标平面，其计算简单，存储空间小，但对不规则的目标紧密性差，边角增加了冗余空间。OBB 则根据目标本身的几何形状来决定包围框的大小和方向，无需和坐标平面平行，从而可以求出更紧凑的包围盒，其实现方法为：首先，使用 PCD 库中的 `get_center()` 方法计算点云的质心 (C_x, C_y, C_z) ，并对点云中的点去中心化，并计算去中心化点的协方差矩阵 Σ ：

$$P' = \{(x_i - C_x, y_i - C_y, z_i - C_z)\} \quad (2.12)$$

$$\Sigma = \frac{1}{N-1} \sum_{i=1}^N P'_i \cdot (P'_i)^T \quad (2.13)$$

接着, 对 Σ 进行特征值分解, 得到表示主方向的三个特征向量组成的旋转矩阵 V , 变换点云:

$$P'' = P' \cdot V \quad (2.14)$$

在新的点云 P'' 中找到坐标轴的最大值和最小值, 由此确定 OBB 的尺寸 (l, w, h) 。

3) 半圆端半径 r_{re} 和半圆端中心距 d_{re} 计算:

$$r_{re} = w * 0.5 \quad (2.15)$$

$$d_{re} = l - w \quad (2.16)$$

由于该桥墩为变截面, 设置厚度 $t = 0.04 \text{ m}$, 基于 OBB 计算其截面参数, 如图 2.19 所示, 其中绿色框为 OBB 计算结果, 红色框为 AABB 计算结果, 可以看出, 与 AABB 相比, OBB 更加紧凑。计算结果显示, 桥墩顶面的半径 $r_{re} = 0.921 \text{ m}$, 中心距 $d_{re} = 0.970 \text{ m}$, 与点云中的手动测量结果 $r_{rem} = 0.910 \text{ m}$, $d_{re} = 0.978 \text{ m}$ 相比, 误差均小于 0.01 m 。其计算误差主要来自点云的噪声和设备的精度限制 (0.01 m)。




图 2.19 圆端形截面的参数提取

Fig. 2.19 Parameter extraction of round end cross-section

(3) 族参数化创建: 点击“文件”选项卡, 新建一个族, 打开“公制常规模型”族样板文件 (*.rft)。在“创建”选项卡“属性”面板打开“族类型”界面, 创建族参数的“名称”、规程、参数类型、参数分组类型, 见图 2.20。

参数	值	公式	锁定
文字			
桥柱编号	0	=	☐
材质和装饰			
桥柱材质	桥柱材质	=	☐
尺寸标注			
底部半圆端半径	0.9140 m	=	☐
底部半圆端中心距	0.5600 m	=	☐
柱底高程	0.0000 m	=	☐
柱顶高程(默认)	7.0490 m	=	☐
顶部半圆端半径	0.9210 m	=	☐
顶部半圆端中心距	0.9700 m	=	☐

图 2.20 桥墩族参数（圆端形截面）

Fig. 2.20 Pier family parameters (round end cross-section)

对于桥墩材质参数的值，打开材质浏览器后，新建命名为“桥墩材质”的材料，并根据工程实际添加基本热量、机械、混凝土等物理性质。在参照标高视图融合创建圆端形，分别对顶部和底部的圆端形的半圆端半径和半圆端中心距进行“半径尺寸标注”和“对齐尺寸标注”，通过鼠标右键选择“标签”命令，设置为“半圆端半径”和“半圆端中心距”。点击圆端形，在属性面板中将拉伸的终点关联至“墩顶高程”参数，将拉伸的起点关联至“墩底高程”参数，完成了族的参数化创建，如图 2.21（a）所示。




图 2.21 桥墩族模型（圆端形截面）：（a）模型（b）叠加点云和模型

Fig. 2.21 Pier family model (round end cross-section):(a) Model (b) Overlay point cloud and model

(4) 构建效果验证：为验证构建的桥墩 BIM 模型与其点云之间的原始坐标匹配和效果，将构建的桥墩模型（.rfa）转换为模型文件（.ply），并在 Cloudcompare 软件中同时打开点云和模型文件（.ply）。如图 2.21（b）所示，点云和模型分别为灰色和绿色，可以看出，点云和模型没有完全重合，这是由于桥墩点云的建模参数来自于拟合，因此，桥墩侧面点云的轻微凹凸是难以避免的。从正面和顶部的视角看，桥墩的重叠效应相当大。综合整体和局部的检查，基于点云构建的桥墩 BIM 模型与点云几乎完全重合。

2.5 本章小结

本章主要介绍了基于 LiDAR 点云的桥墩三维建模方法，重点探讨了 BIM 建模的过程和方法。首先，分析了点云数据在桥梁结构建模中的重要性，其可以准确捕捉现有结构的几何形状和空间位置，为 BIM 模型的构建提供真实的三维信息。其次，详细阐述了 LiDAR 点云的采集和处理方法，包括运动结构和地面激光扫描技术的应用，以及如何通过 CloudCompare 软件进行点云的去噪、配准和处理。

在 BIM 模型的构建部分，本章分别以矩形截面、圆形截面和圆端形截面桥墩为例，介绍了点云分割、参数提取和族参数化创建的具体步骤。通过 α 形状理论、RANSAC 算法和最小二乘法等算法，成功提取了桥墩的几何参数，并在 Revit 软件中构建了相应的 BIM 模型。最后，通过与点云数据的对比验证了模型的准确性，结果表明构建的 BIM 模型与点云数据高度一致。

3 点云强度图和光学图片配准方法

3.1 引言

LiDAR 扫描生成的点云数据包含反射强度和三维坐标信息，但缺乏光谱信息，不利于目标物体的理解和应用，并且点云密度难以满足裂缝识别和量化的精度要求。相比之下，手机镜头等设备采集的彩色光学图片分辨率高、采集成本低，能满足巡检精度需求。因此，融合具有三维坐标的点云与高精度的图片，将两种数据用于裂缝等病害的识别和量化具有可行性。

建立点云强度图和光学图片之间联系的主要方法是采集结构点云的同时拍摄结构的光学图片，开发结构的 LiDAR 点云和光学图片的配准算法，最后，完成光学图片中病害像素坐标到点云坐标系中的映射。该方法主要分为两种模型，即传感器严格模型和经验模型，其中，前者需要依赖 GPS 和 IMU 等传感器建立复杂的模型，设备昂贵且计算复杂，难以满足大量的巡检需求；后者仅仅适用于如大场景点云等特定场景，在纹理较低或重复的场景中配准能力不足。

因此，本章开发了一种基于深度学习的点云强度图和光学照片配准方法。该方法无需 GPS 和 IMU 等传感器，通过基于深度学习的 LoFTR 模型对混凝土结构物点云强度图和光学照片进行同名点提取和匹配，建立了光学图片和点云的联系。

3.2 点云强度图生成

点云具有离散性、稀疏性、高维性。点云强度图是指在点云数据中，每个点除了包含空间坐标外，还包含一个强度值，该值通常表示反射强度或其他特征信息。强度图通过将这些强度值可视化，以帮助分析和理解点云数据的特征。采用投影法生成点云强度图可以将三维点云数据转换为二维图像，直接由投影法生成的点云强度图含有噪声，缺乏丰富的纹理，使得特征提取较为困难。因此，本文提出了一种从低密度、纹理特征不明显的点云生成点云强度图的方法：

(1) 去除噪声：采用 Cloudcompare 中的“分段”操作分离出目标物体点云 P ，使用统计滤波等方法去除目标点云中包含的地面、树木、人群等环境噪声：

$$P = \{v_i\}_{i=1}^n \quad (3.1)$$

其中， n 是点的总数， v_i 是点的坐标向量。

(2) 平面估计：随机采样一致性（RANSAC）算法^[54]通过随机选择数据子集来估计模型参数，并通过评估模型与所有数据点的拟合程度来判断模型的有效性。使用

RANSAC 算法, 指定投影平面, 可以写为:

$$\mathbf{s} \cdot \mathbf{v}_i + d = 0 \quad (3.2)$$

其中 $\mathbf{s}$ 表示平面的法向量, d 表示常数。计算 $\mathbf{P}$ 中所有点到该投影平面的距离, 判断满足一致性条件的点的个数, 重复上述步骤, 直至点的个数满足要求或达到最大重复次数, 由此获得最终的投影平面。

(3) 投影变换: 使用罗德里格斯 (Rodrigues) 旋转公式对点云 $\mathbf{P}$ 进行坐标变换, 得到点云 $\mathbf{P}'$ 。为简化计算, 将其与 YOZ 平面对齐。

$$\mathbf{v}_i' = \mathbf{v}_i \cos(\theta) + (\mathbf{k} \times \mathbf{v}_i) \sin(\theta) + \mathbf{k}(\mathbf{k} \cdot \mathbf{v}_i)(1 - \cos(\theta)) \quad (3.3)$$

$$\theta = \cos^{-1}\left(\frac{\mathbf{k} \cdot \mathbf{s}}{|\mathbf{k}| |\mathbf{s}|}\right) \quad (3.4)$$

其中, $\mathbf{v}_i'$ 表示变换后的点坐标, $\mathbf{k}$ 表示 YoZ 平面的法向量, 即 $(1, 0, 0)$ 。

(4) 目标转正: 围绕中心轴旋转坐标变换后的点云 $\mathbf{P}'$, 直到外接四边形的面积 $A(\gamma)$ 最小, 从而将点云强度图中的目标点云转正, 得到 $\mathbf{P}''$:

$$\mathbf{R}(\gamma) = \begin{pmatrix} \cos(\gamma) & -\sin(\gamma) & 0 \\ \sin(\gamma) & \cos(\gamma) & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad (3.5)$$

$$\mathbf{P}' = \{\mathbf{R}(\gamma) \cdot \mathbf{v}_i\}_{i=1}^n \quad (3.6)$$

$$\gamma^* = \underset{\gamma}{\operatorname{argmin}} A(\gamma) \quad (3.7)$$

(5) 点云渲染: Open3D 库是一个旨在支持点云处理等 3D 数据处理的各种应用的开源库。在 Open3D 库中, `visualization.Visualizer()` 是一个用于渲染和交互式显示点云、网格等几何数据的类。它提供了对渲染窗口的更细粒度控制, 适合需要自定义渲染流程的场景。本文使用 `visualization.Visualizer()` 方法渲染点云, 并调整点大小等参数以平滑点云, 最后将渲染结果保存为点云强度图。

图 3.1 展示了采用上述方法生成的混凝土构件点云强度图像实例。该混凝土构件位于大连理工大学桥隧研发基地, 高约 2m, 长和宽约 1m, 其中投影平面的法向量 $\mathbf{s}$ 用红色箭头表示, 投影平面是混凝土柱的正面, 使用本文提出方法自动生成的点云强度图具有明显的边缘和纹理等特征, 为后续的特征提取和匹配打下了基础。




图 3.1 点云强度图生成方法

Fig. 3.1 Point cloud intensity image generation

3.3 光学图片拼接

3.3.1 最小可检测宽度

本文方法并不局限于光学图像的采集设备，这意味着使用任何满足像素要求的相机，无论是手持设备还是无人机搭载^[55, 56]都是可行的。无人机在裂缝检测中的应用可以提高效率和准确性，但它们无法应用于机场等信号受干扰、背景杂乱或是禁飞区的场景，因此本文采用手机镜头进行研究，以扩展方法的应用场景。

在拍摄光学照片时，最小可检测宽度由镜头到目标物体表面的距离决定。如图 3.2 所示的薄透镜模型，可以使用公式 (3.8)^[41] 计算以毫米为单位的最小可检测宽度 w_r ：

$$w_r = \frac{w_p}{p_c} \cdot \frac{u-f}{f} \quad (3.8)$$

其中 w_p 表示以像素为单位的裂缝宽度； p_c 表示相机传感器的 ppmm（每毫米像素）； f 表示焦距， u 表示工作距离。由计算可得，对于 1mm 宽的裂缝，工作距离不应超过 19.696m；对于 0.5mm 宽的裂缝，工作距离不应超过 9.860m。根据现有算法，最窄可检测的裂缝应至少包含 1 个像素，这意味着单个图像的成像场景很小。在小场景中，纹理较不丰富的图片包含的特征较少，需要进行图像拼接来提升图像和点云强度图配准的效率。




图 3.2 薄透镜模型

Fig. 3.2 Thin lens model

3.3.2 基于 LoFTR 的光学图像拼接方法

本文提出的光学图像拼接主要分为以下三个步骤：

(1) 特征提取和匹配

本文采用基于 Transformer^[57]的深度学习模型 LoFTR^[58]。Transformer 是一种主要应用于自然语言处理任务等序列到序列任务的深度学习模型架构，其引入了自注意力机制使得模型根据输入序列中的不同部分来赋予不同的注意权重，从而更好地捕捉语义关系。

如图 3.3 所示，LoFTR 是一种基于深度学习的局部图像特征匹配方法，它首先在粗粒度上建立像素级密集匹配，然后在细粒度上改进匹配，而不是传统的图像特征检测、描述和匹配的顺序步骤。在户外数据集上的经验评估表明，LoFTR 明显优于当前最先进的方法。由于 LoFTR 具有强大的泛化能力和快速推理速度，它在土木工程检测领域有良好的应用前景，但尚未在土木工程领域的图像拼接任务上得到广泛应用。LoFTR 的网络结构主要由以下几个关键模块组成：

1) 特征提取模块：LoFTR 通过轻量级的 CNN 对输入的两幅图像进行特征提取，生成低分辨率的特征图。该模块提取了图像的局部特征，同时降低了分辨率，节省了计算的开销。

2) 粗匹配模块：LoFTR 通过 Transformer 架构对提取的特征图进行全局建模，利用 Transformer 中的自注意力机制和交叉注意力层来获取两个图像的特征描述符。Transformer 提供的广泛全局感受野使得在低纹理复杂区域进行像素级别的密集匹配成为可能，而传统的特征检测器通常难以在这些区域生成一致的特征点。

3) 细匹配模块：LoFTR 通过该模块对粗匹配结果进行进一步的优化。通过对初步匹配区域进行局部特征增强和精细化处理，模型可以修正粗匹配中的误差，并提高匹配的精度；通过结合高分辨率的特征图，LoFTR 还可捕捉更多的细节信息。

4) 匹配过滤与输出模块：经过粗匹配和细匹配后，LoFTR 会对匹配结果进行过滤，去除不可靠的匹配点对，并输出最终的高质量匹配结果。




图 3.3 LoFTR 网络结构图

Fig. 3.3 Architecture of LoFTR model

MegaDepth^[59]是一个用于深度估计的开创性数据集和基准模型，旨在推动计算机视觉领域中单目深度估计的研究。该项目的主要目标是通过提供大规模的、具有多样性和复杂性的图像数据，来训练和评估深度估计模型，其通常由光学图片和深度图组成，如图 3.4 所示。通过 MegaDepth，能更好地理解 and 改进单目深度估计技术，推动了深度学习在计算机视觉中的应用，尤其是在自动驾驶、机器人导航和增强现实等领域。本文加载在 MegaDepth 数据集上训练的 LoFTR 户外模型参数，将待拼接的两张光学照片输入 LoFTR 模型，并获得对应匹配点的立体对和置信度。

(2) 单应性矩阵估计

单应性矩阵 $\mathbf{H}$ 表示同一场景从不同角度拍摄的两个图像之间的关系。如果图像 I_A 中的一个点 $(x_1, y_1, 1)$ 和图像 I_B 中的一个点 $(x_2, y_2, 1)$ 是对应的匹配点，它们应满足单应性矩阵 $\mathbf{H}$ ：

$$\begin{bmatrix} x_1 \\ y_1 \\ 1 \end{bmatrix} = \mathbf{H} \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix} = \begin{bmatrix} h_{00} & h_{01} & h_{02} \\ h_{10} & h_{11} & h_{12} \\ h_{20} & h_{21} & 1 \end{bmatrix} \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix} \quad (3.9)$$

RANSAC 算法常用于估计两个平面的单应性矩阵，可以稳健地估计矩阵参数。在本文中，将 RANSAC 算法应用于单应性矩阵 $\mathbf{H}$ 的估计，其中重投影误差的阈值设置

为 2.0，迭代次数设置为 1000。




图 3.4 MegaDepth 数据集^[59]

Fig. 3.4 MegaDepth dataset^[59]

(3) 图片变形

图片变形是指将一幅图像 I_B 通过几何变换重投影到另一幅图像 I_A 的坐标系中：

1) 计算 I_B 的坐标系原点 O_B 相对于 I_A 坐标系原点 O_A 的偏移量 ΔO ：

$$\Delta O = O_B - O_A \quad (3.10)$$

2) 将 I_B 的像素点使用公式 (3.10) 映射到参考图片定义的坐标系中，即进行点的坐标变换。

之后，得到了两个在同一坐标系中且具有重叠的共同部分的图片，即两张图片完成了拼接。对于重叠的共同部分，本文尝试了几种过渡平滑算法，包括拉普拉斯金字塔^[60]、加权平均等，但其效果较差。因此，本文没有使用过渡平滑来处理重叠部分，而是采用了在共同部分中待变换图片 I_B 覆盖参考图片 I_A 的方式。

3.3.3 图像拼接方法实例验证

为验证基于 LoFTR 的光学图片拼接方法，本文在混凝土构件的光学照片上进行了实例验证，其比较了 LoFTR 和尺度不变特征变换（SIFT）、加速稳健特征（SURF）等图像拼接任务的常用的传统特征检测器并搭配 K 最邻近暴力匹配器（KNN）。

SIFT^[61]是一种常用于图像特征检测和描述的算法，旨在提取图像中的局部特征点，并对其进行描述，以实现图像匹配和识别。SIFT 算法通过在不同尺度下检测关键点，确保特征对尺度和旋转具有不变性。每个关键点都被赋予一个描述子，该描述子基于其

周围的梯度信息，能够有效区分不同的特征点。

SURF^[62]是另一种常用于图像特征检测和描述的算法，旨在提供比 SIFT 更快的特征提取和匹配性能。SURF 通过使用 Hessian 矩阵的行列式来检测关键点，并采用积分图加速特征计算，从而实现对图像的快速处理。与 SIFT 类似，SURF 也具有尺度不变性和旋转不变性，使其能够在不同的尺度和方向下有效识别特征点。

在特征的匹配环节，常用的算法是 K 最邻近暴力匹配器（KNN）。KNN 是一种简单而有效的特征点匹配方法，常用于计算机视觉中的图像匹配和物体识别任务。在特征点匹配中，KNN 暴力匹配通过计算每个特征点与其他特征点之间的距离，找到最近的 k 个邻近点，从而确定匹配关系。主要包含以下三个步骤：

(1) 距离计算：对于每个特征点的描述子，计算其与另一幅图像中所有特征点描述子的欧式距离 d_f ：

$$d_f = \sqrt{\sum (x_{fi} - y_{fi})^2} \quad (3.11)$$

其中， x_{fi} 和 y_{fi} 是特征点描述子的坐标。

(2) 选择最近邻：根据计算得到的距离，选择距离最小的 k 个特征点作为最近邻。

(3) 匹配筛选：通常情况下，KNN 暴力匹配会选择 $k = 2$ ，利用最近邻和次近邻的距离比值 r_f 来筛选匹配点。如果最近邻与次近邻的距离比小于某个阈值，则认为该匹配是可靠的，从而减少错误匹配的可能性。

$$r_f = \frac{d_{f1}}{d_{f2}} \quad (3.12)$$

其中， d_{f1} 是最邻近的距离， d_{f2} 是次邻近的距离。

实例验证的结果如图 3.5 所示，其中线段表示匹配点之间的连线，可以看出，SIFT 匹配点对数较少（179 对），SURF 匹配点对数较多（274 个），但连线杂乱，质量不高，而 LoFTR 匹配点对数数量最多（343 对），连线均位于重叠区域，匹配质量最高。配对特征点的数量与图像 2 特征点的数量比值反映了算法的效率，从表 3.1 中可以看出，LoFTR 的效率为（58.2%），远高于 SIFT（6.8%）和 SURF（3.1%），证明了 LoFTR 算法的效率较高。




图 3.5 不同算法特征点匹配效果

Fig. 3.5 Performance of different feature point matching algorithms

表 3.1 不同算法的特征点匹配数量

Tab. 3.1 Number of matching feature point for different algorithms

算法	图像 1 特征点数量	图像 2 特征点数量	配对 特征点数量	配对特征点数量/ 图像 2 特征点数量
SIFT (with KNN)	3594	1654	179	6.8%
SURF (with KNN)	9452	8059	274	3.1%
LoFTR	589	589	343	58.2%

3.4 基于 LoFTR 的点云强度图和光学图片配准算法

3.4.1 点云强度图的下采样与轮廓线特征增强

点云强度图缺乏纹理和颜色信息，使用传统的 SIFT 或 SURF 方法提取特征点很困难。因此，在混凝土点云强度图像和光学照片的配准中，本文继续采用 LoFTR 作为特征提取和匹配算法。在将光学照片和点云强度图像输入 LoFTR 之前，本文进行了两个预处理步骤：

(1) 下采样。LoFTR 是一种基于深度学习的模型，其拥有近百万个参数，需要对输入的图片进行下采样，以满足内存限制并加快计算速度。对于点云强度图，其分辨率的大小由点云密度的确定；对于光学图片，下采样后的图片分辨率需要与点云的密度保持一致，以确保特征匹配的准确性和有效性。通过这种方式，LoFTR 能够在保持较高匹配精度的同时，显著降低计算资源的消耗，从而提高整体处理效率。

(2) 轮廓线特征增强。轮廓线是物体边界的连贯线条，能够有效地描述物体的形状和结构特征。轮廓线在计算机视觉中扮演着重要的角色，因为它们能够提供结构物的形态信息，并补充特征点的不足，通过提取轮廓线，计算机视觉系统可以更好地理解和分析图像中的物体^[63]。由于点云数据中存在测量误差、环境干扰或传感器精度不足，点云强度图在结构物轮廓周围往往会出现大量毛刺，导致轮廓线模糊、不清晰，从而影响后续的配准过程。因此，本文对点云强度图中的结构物进行轮廓线特征增强，主要应用概率霍夫变换（PHT）^[55]来找到点云强度图像的轮廓线。PHT 主要包含以下步骤：

1) 边缘检测：使用 Canny 边缘检测算法从输入图像中提取边缘点。Canny 边缘检测算法主要包括以下步骤：首先，使用高斯滤波器对图像进行平滑处理，减少噪声的影响；其次，使用 Sobel 算子计算图像中每个像素的梯度值，确定边缘的强度和方向；再次，在梯度幅值中，进行边缘细化，即抑制梯度幅值图中非极大值的点，只保留局部最大值作为潜在的边缘点，以减少边缘的厚度；接着，通过设置高阈值和低阈值来确定强边缘和弱边缘；最后，通过连接强边缘和与其相连的弱边缘来最终确定边缘，即只有与强边缘相连的弱边缘才会被保留，其余的弱边缘均被抑制。

2) 随机采样：与传统的霍夫变换不同，PHT 无需对所有边缘点进行处理，仅需对边缘点随机采样，以显著减少计算量。

3) 直线参数化：对随机采样到的边缘点 (x_1, y_1) 和 (x_2, y_2) ，通过下列公式将其转化为直线的参数形式：

$$y = mx + b \quad (3.13)$$

其中， m 和 b 均为直线的参数。

4) 参数投票：对于每对边缘点，计算出对应的直线参数，并在参数空间中进行投票。参数空间通常是一个二维数组，其中每个单元格对应于一个特定的直线参数组合。

5) 阈值判断：在参数空间中，经过多次随机采样和投票后，某些参数组合的投票数会显著高于其他组合。通过设定一个阈值，算法可以确定哪些参数组合代表有效的直线。只有当某个参数组合的投票数超过该阈值时，才会被认为是检测到的直线。

6) 直线绘制：检测到的线段使用 1—3 个黑色像素绘制，以覆盖毛刺。




图 3.6 轮廓线特征增强原理

Fig. 3.6 Principle of contour feature enhancement

轮廓线特征增强的原理如图 3.6 所示，LoFTR 提取的特征是点特征和线特征的组合，通过结合点特征和线特征，LoFTR 能够更全面地理解图像内容，从而实现更高效的特征匹配和物体识别。

3.4.2 图像配准算法

LoFTR 的创新之处在于其端到端的设计和 Transformer 的引入，使得它能够在没有显式关键点检测的情况下实现高效、鲁棒的特征匹配。相比传统方法，LoFTR 在处理纹理较少、光照变化大或视角差异显著的图像对时表现出更强的适应性和匹配能力。同 3.3 节中所述，本文加载在 MegaDepth 数据集上训练的 LoFTR 户外模型参数，将轮廓线特征增强后的点云强度图和相应的拼接后的光学照片输入 LoFTR 模型，并获得匹配点的立体对和置信度。对于 LoFTR 输出的匹配点，本文遵循距离约束方法^[50]来删除不正确的匹配对。在本文中，只保留置信度高于 0.75 且满足下式的匹配点对：

$$(x_1 - x_2)^2 + (y_1 - y_2)^2 \leq (0.2 * w)^2 + (0.2 * h)^2 \quad (3.14)$$

其中 w 和 h 分别表示图像的宽度和高度。

为进一步提高低纹理表面图像的配准效果，本文使用通用 Universal Sample Consensus (USAC)^[64]和 M-estimator Sample Consensus (MAGSAC)^[65]算法来估计单应性矩阵 H ，从而去除噪声和异常值，增强鲁棒性估计。USAC 是一种鲁棒性算法，广泛应用于计算机视觉和图像处理领域，特别是在特征匹配和几何模型估计中。它通过灵活的样本选择策略和迭代优化过程，有效处理数据中的噪声和异常值，从而准确估计模型参数。MAGSAC 是一种改进的鲁棒性算法，旨在从包含异常值的数据中准确估计模型参数。它通过引入 M 估计器来优化样本选择和模型评估过程，能够有效地处理高比例的异常值。MAGSAC 结合了随机采样和局部优化的优势，提供了更高的准确性和效率，在处理复杂场景时表现出色，能够快速收敛到可靠的模型参数。接着，本文将点云强度图作为参考图像，对光学图片进行变换。

如图 3.7 所示，通过基于 LoFTR 的点云强度图和光学图片配准算法，变形后光学图片的混凝土表面 S_0 对应于点云强度图的混凝土表面 S_1 ，而 S_1 对应于同一混凝土点云 S_2 ，由此完成了光学图片 S_0 （像素级）和点云 S_2 （mm 级）的对应。在具体的层级来看，光学图片中的一点 $A_0(x_0, y_0)$ 对应于点云强度图中的点 $A_1(x_1, y_1)$ ，由此对应于点云中的点 $A_2(x_2, y_2, z)$ ，即将光学图片和点云建立了对应关系，为裂缝的识别和量化打下了基础。




图 3.7 点云强度图和光学照片的对应关系

Fig. 3.7 Correspondence between point cloud intensity map and optical image

图片的分辨率 pr 是指单位长度内像素点的数量。为了确定光学图片中物体的真实尺度，本文对 pr 进行计算：

(1) 计算点云中物体的表面积：应用 α 形状算法^[66]提取 S_2 的轮廓并计算其表面积 $S(S_2)$ （单位为 mm^2 ），通过调整参数 α ，控制生成的形状的细节程度，从而捕捉到点集的轮廓和结构。

(2) 计算光学图片中物体的面积：光学图片中的物体与背景难以区分，而点云强度图中的背景均为白色像素，因此，将光学图片中物体的面积定义为点云强度图中非白色像素的区域，即 $S(S_1)$ （单位为像素）。

(3) 计算分辨率 pr ：

$$pr = \frac{S(S_1)}{S(S_2)} * r \quad (3.15)$$

其中， r 为点云强度图的下采样率。

3.5 本章小结

本章首先介绍了深度学习的基本原理，作为后续研究的理论基础。接着，提出了一种从低密度、纹理特征不明显的点云生成点云强度图的方法，该方法通过 Open3D 渲染点云，提升了点云强度图的纹理。然后，本章针对小场景下的光学图片提出了基于 LoFTR 的光学图像拼接方法，该方法的实例验证显示其在特征提取和匹配能力上优于传统的特征检测算法（如 SIFT 和 SURF）。最后，本章先对点云强度图进行下采样操作以节省运算资源，再基于概率霍夫变换直线检测进行轮廓线特征增强，基于 LoFTR 完成了点云强度图和光学图片的配准，并使用 USAC 和 MAGSAC 增强了配准的鲁棒性。通过本章提出的点云强度图和光学图片的配准方法，本文建立了点云和光学图片中像素的对应关系，并完成了光学图片分辨率的计算，为裂缝的识别和量化奠定了基础。

4 裂缝识别与量化

4.1 引言

在使用基于 LoFTR 的点云强度图和线特征增强后的光学图片进行配准后, 本文建立了点云的点和光学图片的像素之间的对应关系, 得到了像素分辨率这一联系像素大小和真实大小的指标。因此, 在光学图片中识别和量化裂缝就成为了本章的主要任务。

随着图像处理技术的发展, 许多的智能算法被应用于裂缝识别中, 以替代传统的人工目视检查。Mohan 等^[67]总结了在工程结构裂缝检测中大量使用的算子和算法, 包括腐蚀、膨胀等形态学方法、小波变换、霍夫变换、sobel 算子和 canny 算子等。在光照条件不足、背景复杂、噪声较多的环境下, 传统算法的精度不足, 而基于深度学习网络的算法可以达到很高的精度。上述算法可以精确的得到裂缝和背景的二值图, 然而, 识别算法仅仅对裂缝进行了定位, 不能评估裂缝的严重程度。

为评估裂缝的严重程度, 需要对裂缝检测算法输出的二值化图片进一步处理。在裂缝的长度、宽度、深度和间隙等特征中, 宽度是很大程度上决定裂缝严重程度的关键指标^[68]。裂缝宽度难以量化的问题在于没有明确的定义, 一种主流的算法是先提取裂缝的骨架, 然后根据骨架点的切向方向或距离来定义该点的裂缝宽度, 这种算法目前仍存在着骨架剪枝算法时间复杂度高、鲁棒性不强等问题。

因此, 本章先提出基于深度学习的 YOLOv8-seg-CBAM 模型, 对裂缝进行实例分割; 然后, 完善基于骨架和图的裂缝宽度量化算法, 以此得到裂缝的像素宽度, 结合像素分辨率得到裂缝的宽度信息。

4.2 基于深度学习的裂缝实例分割

4.2.1 YOLOv8-seg-CBAM

深度学习图像分割模型主要分为语义分割和实例分割, 与传统的图像分割方法相比, 深度学习模型能够自动学习特征表示, 从而获得更高的分割精度。语义分割旨在将图像中的每个像素分类为特定的类别, 在语义分割中, 输入图像被分割成多个区域, 每个区域对应于一个特定的类别, 例如裂缝、渗漏水、混凝土等。常用的基于深度学习的语义分割模型包括 FCN^[69]和 U-Net^[70]等。这些模型通过多层卷积和池化操作提取图像特征, 并通过上采样恢复到原始图像的分辨率, 生成像素级的分割掩码。与语义分割不同, 实例分割不仅要识别每个像素的类别, 还要区分同一类别中的不同实例, 即先后完成目标检测和语义分割两大任务。Mask R-CNN^[71]是实例分割的经典模型, 它在目标检测的基

基础上增加了一个分支，用于预测像素级的分割掩码。

如图 4.1 所示，YOLOv8^[72]是一种最先进的目标检测算法，它将目标检测任务转化为回归问题，通过单个神经网络实现高精度和实时性能，其包含用于特征提取的主干、用于多尺度特征融合的颈部，以及用于目标分类和定位的头部。如图 4.1 中虚线框所示，YOLOv8 的 Bottleneck 模块减少了参数数量和计算复杂度；C2F 模块则通过跨阶段连接来增强特征的流动性，提高了模型的特征传递和融合能力；CBS 模块提升了模型的特征提取能力。基于 YOLOv8 的目标检测能力，YOLOv8-seg 通过为每个检测到的对象实例生成像素级分割掩码来扩展这一功能，即作为一种实例分割算法，YOLOv8-seg 结合了目标检测和语义分割任务，改善了两种任务分开进行时效率低下的问题，其效果良好。




图 4.1 YOLOv8-CBAM-seg 结构图

Fig. 4.1 Architecture of YOLOv8-CBAM-seg

在此基础上，本文提出了实例分割模型 YOLOv8-CBAM-seg，这是 YOLOv8-seg 的增强版本，集成了卷积块注意力模块（CBAM）^[32]。为了增强模型对图像中重要区域的关注能力，融入了 CBAM（图 4.1 中红框部分），这是一种混合时间和空间的注意力机制，其通过动态调整对关键特征的关注，提高了模型的特征感知能力和整体性能。

当成像平面远离裂缝等缺陷时，算法的分割效果通常会下降^[73]。为了解决这个问题，本文根据公式 (3.3) 限制工作距离，以确保检测的准确性。CBAM 的引入使 YOLOv8

模型能够更好地捕捉裂缝的细节特征，显著提高了实例分割的准确性。与传统的分开使用目标检测和语义分割的方法相比，这种单阶段方法在检测效率和分割质量之间取得了更好的平衡。

4.2.2 算法训练、测试

对本文提出的 YOLOv8-CBAM-seg 算法进行训练和测试。数据集是深度学习模型训练、验证、测试的基础，在本实验中，本文使用了来自 SDNET2018 数据集的 400 张图片进行网络训练和验证、测试。SDNET2018 数据集^[74]是一个用于混凝土裂缝检测算法研究的基准数据集，包含桥梁、墙壁和道路等各种混凝土结构的图片。图片统一调整成 224×224 像素的大小，然后使用开源软件 labelme 对数据集标注，如图 4.2 所示，通过 Create Polygons 工具描绘堆石料轮廓生成.json 标注文件，并利用 Python 程序将其转换为.png 格式的 8 位灰度掩码图和.txt 文件，以用于深度学习分割模型的训练、测试和验证。标注完成后，使用 Python 的 random 模块将数据集按 81:9:10 的比例划分为训练集、验证集和测试集，分别包含 324 张、36 张和 40 张。




图 4.2 Labelme 数据集标注

Fig. 4.2 Dataset annotation using Labelme

本文基于 PyTorch 框架构建了 YOLOv8-CBAM-seg 模型。PyTorch 由 Facebook 团队于 2017 年推出，具有简洁、高效、易上手的特点。本文的实验环境的软硬件配置如表 4.1 所示。YOLOv8-CBAM-seg 模型参数众多，而裂缝实例分割的训练集仅有 324 张图片，每张包含 1-2 个病害样本，难以满足模型充分训练需求。为解决小样本问题，采用迁移学习策略，以 COCO 数据集^[75]上预训练的模型参数为起点，通过实例分割数据集微调参数，加速模型收敛。训练中使用 AdamW 优化器（学习率 0.002，动量 0.9），训练 300 轮，批大小为 8，并通过马赛克、随机缩放、长宽扭曲和翻转等在线数据增强策略提升

模型性能。

表 4.1 实验环境的软硬件配置

Tab. 4.1 Software and hardware configuration of the experimental environment

软硬件		配置
硬件	CPU	Intel Core i7-12700H
	GPU	NVIDIA GeForce RTX 3060
	系统	Windows 11
软件	语言	Python 3.7.13
	深度学习框架	PyTorch

训练的损失曲线如图 4.3 所示, 轮数在 250 轮开始时, 验证集的损失函数均趋于定值, 选取 250 轮之后的分割损失函数曲线最小值的训练结果作为模型加载的权重进行测试。在训练过程使用公式 (4.1)~(4.4) 定义的评估指标进行监控:

$$R = \frac{TP}{TP+FN} \quad (4.1)$$

$$P = \frac{TP}{TP+FP} \quad (4.2)$$

$$AP = \int_0^1 P(R) \quad (4.3)$$

$$mAP@50 = \frac{1}{c} \sum_{i=1}^c AP@50_i \quad (4.4)$$

其中, R 表示模型预测的召回率, P 表示精确率, TP 指正确分类为正样本的样本数量, FP 指错误分类为正样本的样本数量, FN 指错误分类为负样本的样本数量。 AP 表示在不同置信度阈值下特定类别的精确率-召回率曲线下的面积。 $mAP@50$ 表示平均精确率, 通过在交并比阈值为 0.5 的情况下对各类别的 AP 进行平均计算得出, c 表示类别的数量。

YOLOv8-CBAM-seg 模型与 U-Net、AlexNet^[76]和 YOLOv8-seg 等三种常用的实例分割模型在测试数据集上的表现总结见表 4.2。在所有模型中, U-Net 表现最差, 召回率 (84.0%) 和精确率 (87.0%) 显著低于其他模型。AlexNet 实现了最高的召回率 (92.4%), 略高于 YOLOv8-seg 模型, 突显了其在检测正实例方面的有效性。引入 CBAM 模块的 YOLOv8-CBAM-seg 算法在精确率 (96.7%) 和 $mAP@50$ (94.9%) 方面优于其他方法, 展示了其在裂缝分割任务中的高准确性和鲁棒性, 证明了其改进的有效性。




图 4.3 训练损失曲线

Fig. 4.3 Loss curve of the training stage

表 4.2 裂缝数据集上不同分割算法的表现评估

Tab. 4.2 Performance evaluation of different segmentation algorithms on the crack dataset

Algorithm	$mAP@50$	召回率	精确率
U-Net	/	84.0%	87.0%
AlexNet	/	92.4%	93.2%
YOLOv8x-seg	92.2%	92.1%	91.1%
YOLOv8x-CBAM-seg	94.9%	91.8%	96.7%

这些模型在测试数据集图片的表现如图 4.4 所示：U-Net 模型的精确率较低，其掩码大于裂缝的实际宽度，YOLOv8-seg 模型准确识别和分割了裂缝，其精确率和召回率较高，而 YOLOv8-seg-CBAM 模型则在此基础上进一步提高了精确率，掩码与裂缝的实际轮廓更契合。这些结果图片将进一步转化为裂缝和背景的二值图片，以进一步提取裂缝的宽度等信息。




图 4.4 测试集结果：(a) U-Net (b) YOLOv8-seg (c) YOLOv8-seg-CBAM

Fig. 4.4 Loss curve of the training stage: (a) U-Net (b) YOLOv8-seg (c) YOLOv8-seg-CBAM

4.3 基于骨架和图的裂缝量化

4.3.1 裂缝骨架提取

裂缝可以在宽度、长度、深度等方面进行量化，在 YOLOv8-CBAM-seg 算法获取到含有裂缝的二值图像后，本文提出了一种基于裂缝骨架的裂缝宽度和长度量化方法。在进行裂缝量化之前，需要对二值图像预处理，即分离出二值图像中各条不相交的裂缝，以独立计算，避免互相干扰。这一步骤是通过 Open Source Computer Vision Library (OpenCV) 库中 `connectedComponentsWithStats` 函数对二值图像中内部八向连通域计算完成的（连通性参数设置为 8）。

对于分离出的单条裂缝，裂缝量化方法首先需要裂缝骨架提取。裂缝骨架是裂缝斑块的基本结构，代表了裂缝的跨度^[77]。Medial Axis Transform (MAT) 算法^[78]和 Zhang-Suen 算法^[36]是两种用于图像骨架化的方法，它们在处理图像时有不同的特点和适用场景：MAT 算法基于图像的几何特性，可以提供更准确的中轴表示；其通常与距离变换结合使用，可以提供骨架点到原始边界的距离信息。与 MAT 算法相比，Zhang-Suen 算法的计算复杂度更低，可以节约运算资源，并使得裂缝的骨架进一步细化。因此，本文首先采用 MAT 算法对裂缝骨架进行提取。如图 4.5 所示，MAT 算法首先找到二值图像上的所有最大圆盘。最大圆盘即圆盘至少两个点上与边界相切，这些点不在其他圆盘中。这些圆盘的圆心点即为 MAT 算法得到的裂缝骨架点。




图 4.5 MAT 算法提取裂缝骨架

Fig. 4.5 MAT algorithm for extracting crack skeleton

对于分离出的单条裂缝结果，还需要解决以下两个问题：一是裂缝宽度是裂缝表面与正常表面之间的开口间隙，裂缝宽度应沿裂缝骨架的跨度垂直测量^[38]。在交叉点上裂缝的宽度缺乏测量标准^[68]，因此需要去除裂缝交叉点，将其转化为单个线段来逐点计算宽度。二是由于裂缝的锯齿状边界，裂缝骨架点中经常包含一些不能描述裂缝骨架结构

的“虚假点”，其影响了下一步宽度计算的准确性。

对于这两个问题，先前的研究^[38, 68, 79]通常解决思路为：先使用 Discrete Curve Evolution (DCE) 算法^[80]剪除虚假的分支，再将修剪后的裂缝骨架转化为由节点和边定义的图，计算节点的度以找到交叉点（节点的度大于 2），并使用中点圆算法将交叉点周围的像素去除，使得单个裂缝成为数条可计算的线段。然而，DCE 算法需要根据图片和裂缝大小指定阈值，容易造成修剪不足或修剪过度^[79]；运算量较大，修剪步骤占据整个宽度量化算法大部分运算时间^[81]。因此，本文提出了一种基于树的深度优先搜索算法的骨架剪枝算法（DFS 剪枝算法），以解决 DCE 算法中存在的问题。

4.3.2 基于形态学操作的裂缝交叉点去除算法

算法的第一步是去除裂缝的交叉点，使得裂缝的骨架从包含环的图转化为树。这一步的重点是去除裂缝交叉，而非具体的裂缝宽度量化实现。常用的中点圆算法的解决思路是：以端点为圆心，从 1 像素开始逐步增大圆的半径，直至圆与裂缝边界的焦点数量等于端点度的 2 倍。该方法在混凝土裂缝极细的情况（如裂缝的宽度在 1 或 2 像素）时可能会失效。因此，本文提出了基于形态学变换的去除裂缝交叉点方法：

(1) 使用 OpenCV 库中的十字形膨胀函数来去除裂缝的锯齿状边界，以防止“虚假骨架点”的存在使得裂缝的分割过于细碎。为控制锯齿状边界去除和原骨架保留的平衡，设置参数 O 加以限制：

$$O = \frac{|P_1 \cap P_2|}{|P_1|} \quad (4.5)$$

其中 P_1 和 P_2 分别是使用膨胀函数前后的裂缝骨架，其均由 Zhang-Suen 算法提取以提高运算速度。设置 O 大于 0.95 的条件，来自适应的设置膨胀函数的迭代次数。

(2) 对于去除锯齿状边界后得到的裂缝骨架，将其转化为由节点 N 和边 E 定义的树：

1) 逐骨架点 p_i 由八邻域法计算其度 $D(p_i)$ ，并由公式 (4.6) 确定 p_i 的性质。

$$\begin{cases} p_i \in E, \text{ if } D(p_i) = 2 \\ p_i \in N, \text{ if } D(p_i) = 1 \vee D(p_i) > 2 \end{cases} \quad (4.6)$$

2) 对于 S_n ，通过 DBSCAN 聚类算法^[82]将其聚类成各个节点子集 N_i 。

3) 对每个节点子集 N_i ，搜索 E 中的相邻点 p_n ，将其移至边子集 E_i ，直至 E 中无相邻点后，搜索节点集中最近的两个相邻点并移至 E_i 。

(3) 对于每一条边 E_i 内的两个端点，由其法线方向和反方向上最近的两个边界点进行 1 像素的线条分割，由此完成裂缝交叉点的去除。其中，裂缝的边界点为膨胀前的原裂缝边界 B_0 ，由 canny 边缘检测算法得出。如图 4.6 所示，裂缝骨架的一点方向由

Principal Component Analysis (PCA) 算法确定, 即使用 5×5 或 3×3 大小的滑动块内的裂缝像素 (x_i, y_i) 二阶矩 θ 作为滑块的方向, $\theta + \pi/2$ 作为骨架点的法线方向, 公式如下:

$$\theta = \tan^{-1} \left[\frac{|\mu_{xx} - \mu_{yy}| + \sqrt{(\mu_{xx} - \mu_{yy})^2 - 4\mu_{xy}^2}}{2\mu_{xy}} \right] \quad (4.7)$$

其中, $\mu_{xx} = \sum_i^N \frac{(x_i - \bar{x})^2}{N} + \frac{1}{12}$, $\mu_{yy} = \sum_i^N \frac{(y_i - \bar{y})^2}{N} + \frac{1}{12}$, $\mu_{xy} = \sum_i^N \frac{x_i \cdot y_i}{N}$ 。

(4) 重复 4.3.1 节中连通域算法, 分离出不相交的裂缝。




图 4.6 裂缝骨架点局部方向的定义

Fig. 4.6 Definition of the local orientation of crack skeleton points

如图 4.7 所示, 基于形态学操作的裂缝交叉点去除方法成功去除了裂缝的交叉点, 与使用中点圆算法的 Ong 等^[79]达到了基本相同的效果, 同时从原理上解决了极细裂缝的交叉点去除问题。




图 4.7 基于形态学操作的裂缝交叉点去除: (a) 二值图像 (b) 交叉点去除结果

Fig. 4.7 Removal of crack intersections based on morphological operations: (a) Binary image (b) Intersection removal result

4.3.3 基于 DFS 的裂缝骨架剪枝和长度计算

算法的第二步是裂缝骨架剪枝。DCE 算法量化了某一条边的保留对于基于裂缝骨架对整条裂缝进行重建时的贡献率 w_i :

$$w_i = 1 - \frac{A(R(P_1 - E(p_i, f(p_i))))}{A(E(P_1))} \quad (4.8)$$

其中, $A()$ 表示计算面积, $R()$ 表示对裂缝进行重建, $E()$ 表示由骨架点 p_i 到 $f(p_i)$ 确定的骨架分枝。DCE 算法通过设置阈值, 如 0.005^[68], 来筛选满足阈值要求的骨架分枝。

基于树的最大直径的裂缝骨架剪枝算法 (DFS 算法) 则从裂缝骨架体现裂缝跨度的定义出发, 将裂缝骨架视为树结构中节点最远距离, 即最大直径。从算法复杂度的角度分析, 对于同样的节点数量 n , DCE 算法的时间复杂度为 $O(n^2)$, 本文算法的时间复杂度为 $O(n)$, 节约了计算时间, 同时无需指定阈值。其主要包含以下步骤:

(1) 使用 MAT 算法提取裂缝骨架, 并将其转化为树, 树的节点和边的定义方法由 4.3.2 小节给出, 其中边的长度 l 由 i 个点之间的距离 d 确定^[38]:

$$d_i = \begin{cases} |x_{i-1} - x_i| + (\sqrt{2} - 1)|y_{i-1} - y_i|, & \text{if } |x_{i-1} - x_i| > |y_{i-1} - y_i| \\ |y_{i-1} - y_i| + (\sqrt{2} - 1)|x_{i-1} - x_i|, & \text{if } |x_{i-1} - x_i| \leq |y_{i-1} - y_i| \end{cases} \quad (4.9)$$

$$l = \sum d_i \quad (4.10)$$

(2) 使用两次深度优先搜索 (DFS) 算法, 找到树的最大直径, 其节点和边组成的路径即为修剪后的裂缝骨架, 裂缝的长度为边 l 的累和 l_{sum} ^[38]:

$$l_{sum} = \sum l_i \quad (4.11)$$

如图 4.8 (a) ~ (c) 所示, 对于一条裂缝骨架实例, 基于树的最大直径的裂缝骨架剪枝算法将裂缝骨架转化为了以节点 (图 4.8 (b) 中红色) 和边 (图 4.8 (b) 中绿色) 定义的树形数据结构, 由深度优先搜索算法可以确定 $14 \rightarrow 25 \rightarrow 24 \rightarrow 23 \rightarrow 19 \rightarrow 8 \rightarrow 18 \rightarrow 15 \rightarrow 17 \rightarrow 16 \rightarrow 22 \rightarrow 20 \rightarrow 21 \rightarrow 6$ 为树的最大直径, 即去掉“虚假骨架点”后的裂缝骨架。如图 4.8 (d) 所示, 基于树的最大直径的裂缝骨架剪枝算法的骨架剪枝结果 (图中红色部分) 撑起了整个裂缝的跨度, 效果良好。




图 4.8 基于 DFS 的裂缝骨架剪枝算法：(a) 二值图像 (b) 未剪枝的裂缝骨架 (c) 树形数据结构 (d) 剪枝后的裂缝骨架

Fig. 4.8 Tree-based maximum diameter crack skeleton pruning algorithm: (a) Binary image (b) Unpruned crack skeleton (c) Tree data structure (d) Pruned crack skeleton

为进一步说明基于 DFS 的裂缝骨架剪枝算法和 DCE 算法的应用效果,如图 4.9(a)所示,在 Ong 研究的条件下^[79],本文使用了 CrackForest^[83]中的两张含有裂缝的二值图片(左为水平裂缝,右为斜裂缝)对比了 DFS 和 DCE 算法,其中, DCE 算法的阈值为 75 保持一致。如图 4.9 (b) 所示, DFS 算法对裂缝骨架的剪枝效果良好,而如图 4.9 (c) 所示, DCE 算法没有成功对裂缝骨架进行剪枝,还有部分虚假的裂缝骨架保留(图中绿色线条)。




图 4.9 DFS 算法和 DCE 算法比较：（a）二值图像（b）DFS 算法结果（c）DCE 算法结果
Fig. 4.9 Comparison of DFS algorithm and DCE algorithm: (a) Binary image (b) DFS algorithm result (c) DCE algorithm result

4.3.4 EOB 算法计算裂缝宽度

如图 4.10 所示，主流的裂缝宽度量化算法包括 skeleton shortest distance（SSD）算法^[84]、Orthographic Projection（OP）算法^[38]、Edge Shortest Distance（ESD）算法^[79]、

OrthoBoundary (OB) 算法^[68]。对于 OP 算法和 OB 算法，两者都先确定了裂缝骨架点 p_i 的局部方向向量 L ，OP 算法寻找正交方向上和反方向上最近的点 p'_1 和 p'_2 ；OB 算法在此基础上使用 PCA 算法计算点 p'_1 和 p'_2 的局部方向向量 L'_1 和 L'_2 ，将其转换为正交坐标系中的角度值 L 、 L'_1 和 L'_2 ，并计算它们的平均值 L_{aver} ，然后将其转换为该点的修正局部方向向量 L_c ，寻找正交方向上和反方向上最近的点 p''_1 和 p''_2 ，两者均将找到的这对点的欧氏距离估计为该点的裂缝宽度。




图 4.10 裂缝宽度算法计算原理：(a) SSD (b) OP (c) ESD (d) OB (e) EOB

Fig. 4.10 Principle of crack width calculation algorithm: (a) SSD (b) OP (c) ESD (d) OB (e) EOB

OB 算法可以看作对 OP 算法的进一步完善,但两者都仅仅考虑到了裂缝骨架点的宽度方向正交于这一点的局部方向,在后续计算中未考虑到像素的离散性,仅依靠方向找到最近点,这会导致在曲率较大的裂缝骨架点找到错误的估计点,导致估计偏大^[79]。SSD 算法在裂缝骨架点 p_i 的两侧边界点上找到欧式距离最近的一对点 p_1''' 和 p_2''' , 将其欧式距离估计为该点的裂缝宽度,由于未对正交性加以限制,SSD 算法常常对裂缝的宽度估计过小^[79]。ESD 算法由于同时考虑了正交性和像素离散性的限制,因此,本文通过上述比较,选用 ESD 算法和 OB 算法联合,即为 EOB 算法来估计裂缝的宽度。

与这些主要应用于沥青路面裂缝量化算法不同,由于混凝土裂缝较沥青裂缝较细,EOB 算法考虑了 1-2 像素宽的裂缝量化。通过方向角 θ 可以确定裂缝所有像素点在 p_i 正交方向 $\mathbf{o}$ 上的数量 n 。当 $n = 1$ 时,这一点的裂缝宽度 $w_i = 1$; 当 $n = 2$ 时,这一点的裂缝宽度 w_i 为两点的欧氏距离; 当 $n > 2$ 时,按照 ESD 算法进行计算,即对于某一骨架点 p_i ,由公式(4.3)确定其方向角 θ ,由 OB 算法得到正交单位向量 $\mathbf{o}$; 对于边界点集合 B_0 中的点 $b_i(x_i, y_i)$,由 p_i 确定候选单位向量 $\mathbf{c}_i$,计算 $\mathbf{c}_i$ 关于 $\mathbf{o}$ 的投影系数 Pro_i :

$$Pro_i = \mathbf{o} \cdot \mathbf{c}_i \quad (4.12)$$

接着,可以得到两个极值 Pr_{max} 和 Pr_{min} ,找到满足下式的点的集合 B_1 和 B_2 :

$$B_1 = B[\frac{P}{P_{max}} > 0.999] \quad (4.13)$$

$$B_2 = B[\frac{P}{P_{max}} > 0.999] \quad (4.14)$$

计算 B_1 中所有点和 B_2 中所有点最短的距离 d_{min} ,即为骨架点 p_i 的裂缝宽度 $w_i = d_{min}$ 。对于这条裂缝,宽度 W (以毫米为单位)是每个点的宽度的平均值:

$$W = \frac{1}{N} \sum_{i=1}^N W_i * pr \quad (4.15)$$

为说明裂缝宽度量化算法的效果,分别使用 ESD、OB、EOB 算法对 CrackForest^[83] 的一张含有裂缝的二值图片进行宽度量化,如图 4.11 所示,图 4.7 (b) ~ (d) 中绿色线条即为裂缝在某一骨架点的宽度表示,可以看出:三种算法均取得了良好的宽度量化效果,绿色线条的方向与骨架点的正交方向基本一致,图 4.11 (b) 中 ESD 算法的部分结果存在一定的偏差,对宽度的估计略大;图 4.11 (c) 中 OB 算法绿色线条的方向部分偏离了骨架点的正交方向,对宽度的估计也略大;而 EOB 算法的绿色线条方向与骨架点的正交方向更为一致,未出现偏差,宽度量化更为合理。




图 4.11 裂缝宽度量化算法效果对比：(a) 二值图像 (b) ESD (c) OB (d) EOB

Fig. 4.11 Comparison of crack width quantification algorithm effects: (a) Binary image (b) ESD (c) OB (d) EOB

本文还以 4.2 节中实例分割数据集中的真实混凝土裂缝为基础,对 EOB 算法在二值图片上的量化误差进行了实验:以 MAT 算法提取裂缝实例分割数据集中的裂缝骨架,分别以 2~19 像素大小的半径作裂缝骨架的中点圆,生成已知半径的裂缝 18 条,合成数据集如图 4.12 所示;使用 EOB 算法量化裂缝的宽度,其相对误差的平均值为-5.3%,说明了 EOB 算法的效果良好。




图 4.12 裂缝合成数据集

Fig. 4.12 Crack synthetic dataset

4.4 本章小结

针对裂缝的实例分割任务，本章引入 CBAM 注意力机制至 YOLOv8-seg 模型的骨架部分，提升了模型对特征的表达和学习能力，提出了 YOLOv8-seg-CBAM 模型；在 SDNet2018 数据集的基础上搭建了 400 张图片的裂缝实例分割数据集，以此为基础进行模型的训练、验证和测试，与 YOLOv8-seg 模型相比，YOLOv8-seg-CBAM 模型的 $mAP@50$ 提升了 2.7%，精确率提升了 5.6%，证明了改进的有效性。

针对裂缝的宽度和长度量化任务，本章提出了基于膨胀算法的裂缝交叉点去除算法和基于 DFS 的裂缝骨架剪枝算法，其时间复杂度为 $O(n)$ ，优于 DCE 算法 $O(n^2)$ ，且无需阈值；算法还考虑了混凝土裂缝较细的特点，对裂缝宽 1-2 像素时的情况加以考虑；最后，综合 ESD 算法对于像素离散性和 OB 算法对于骨架点方向修正提出了 EOB 算法，其在合成数据集上的相对误差的平均值为 -5.3%，与现有算法的比较实验证明了 EOB 算法的优越性。

5 工程验证

5.1 引言

为验证本文所提出的方法在实际数据上的有效性和精度，本文设计了工程验证实验。基于激光点云对桥墩进行快速建模，并在混凝土结构物的平面和曲面上，基于激光点云和图像数据对裂缝进行三维的量化，并对结果进行模型展示。

5.2 数据获取

如图 5.1 所示，本文选择了大连理工大学北门附近的一座人行天桥进行实验，该桥具有圆端形截面的混凝土桥墩。每个桥墩的前后面是平面，左右两侧是曲面。为验证所提出算法的精度，在北侧桥墩（图中红框）的南面（以下简称正面）和东面（以下简称侧面）分别粘贴了 6 条和 9 条固定宽度的胶带，其宽度范围为 1mm 到 10mm，同时，使用该桥墩南面的真实裂缝验证本文算法的实际有效性。

本文使用 2.2 节介绍的 GOSLAM RS100S 移动激光雷达系统进行点云数据采集，通过手持的采集方式稳步绕着桥墩行走，进行了进行 360° 扫描。另一方面，使用 iPhone 15 Pro Max 的主摄像头进行光学图片的采集，该摄像头具有 4800 万像素和 24mm 焦距。根据公式 (3.15) 计算拍摄距离将其限制在 8m 以内，并从不同角度收集图片，以确保图片分辨率满足量化精度。对于该桥墩，LiDAR 数据采集花费了 5min，而光学图片拍摄持续了 2min。



图 5.1 实验现场和图像采集设备的照片

Fig. 5.1 Photos of the experiment site and image collection devices

5.3 基于 LiDAR 点云的桥墩建模

在 LiDAR 采集点云的基础上, 对点云进行了去噪等预处理操作, 得到了如图 5.2 (a) 所示的桥墩点云。由于桥墩的截面为圆端形, 采用基于 OBB 包围盒的方法对截面进行参数提取, 计算结果显示, 桥墩顶面的半径 $r_{re} = 0.392 \text{ m}$, 中心距 $d_{re} = 3.009 \text{ m}$, 与点云中的手动测量结果 $r_{rem} = 0.400 \text{ m}$, $d_{re} = 3.000 \text{ m}$ 相比, 误差均小于 0.02 m 。其计算误差主要来自点云的噪声和设备的精度限制 (0.01 m)。对桥墩进行参数化建模, 结果如图 5.2 (b) 所示。




图 5.2 桥墩建模: (a) 点云 (b) BIM 模型

Fig. 5.2 Pier modeling: (a) Point cloud (b) BIM model

5.4 点云强度图和光学图片配准

基于 LoFTR 算法对人行桥桥墩的光学图片进行拼接, 如图 5.3 (a) 所示, 拼接后的光学图片包含了完整的桥墩南侧立面, 在图片的拼接区域 (图中虚线附近) 没有观察到明显的变形, 证明了拼接效果良好。另一方面, 使用本文所提出的强度图生成方法生成桥墩 LiDAR 点云强度图, 如图 5.3 (b) 所示, 原始点云是离散、不平滑的, 而点云强度图则表现出了显著的纹理特征, 为下一步特征提取和匹配打下良好基础。



图 5.3 图像预处理：（a）光学图片拼接（b）强度图像生成

Fig. 5.3 Pre-processing of images: (a) Optical image stitching (b) Intensity image generation

在点云强度图和光学图片配准环节，先采用下采样的方法将光学图片与点云强度图的大小进行匹配，并满足 LoFTR 网络运行的内存限制，接着，采用基于 PHT 的轮廓线增强方法对点云强度图的线特征进行增强，并基于 LoFTR 算法对点云强度图和光学图片进行配准。为验证本文方法的有效性，还应用了 SIFT、SURF 图像特征点提取算法和 KNN 特征点匹配算法，其结果如图 5.4 所示。如图 5.4（a）和（b）所示，SIFT 和 SURF 仅提取了少量的特征点，而 KNN 算法输出的对应特征点连线几乎全部错误，结果表明，传统的图像配准方法缺乏在低纹理表面上匹配特征点的能力。如图 5.4（c）所示，使用 LoFTR 算法时，尽管特征点的数量没有显著增加，但点云强度图和光学图片之间的匹配准确性大大提高；在较为光滑的混凝土表面等低纹理区域观察到了特征点的正确匹配，表明 LoFTR 算法在低纹理表面上的良好性能。此外，本文验证了轮廓线特征增强的有效性，如图 5.4（d）所示，LoFTR 算法输出的正确匹配的特征点数量显著增加（图中红框），表面轮廓线特征增强策略显著改善了轮廓附近等区域的特征点匹配。




图 5.4 特征点提取和匹配的结果使用：(a) SIFT+KNN (b) SURF+KNN (c) LoFTR (d) 线特征增强的 LoFTR

Fig. 5.4 Results of feature points extraction and matching using: (a) SIFT+KNN (b) SURF+KNN (c) LoFTR (d) Line feature augmented LoFTR

表 5.1 总结了使用上述不同方法获得的匹配特征点数量。与传统特征点提取方法（如 SIFT 和 SURF）相比，基于深度学习的 LoFTR 算法在低纹理表面上将特征点数量增加并提高匹配准确性近 100%。当增强线特征时，正确匹配点的数量比原始 LoFTR 算法增加了 64%，证明了轮廓线特征增强策略的有效性。

表 5.1 不同算法的特征点匹配数量

Tab. 5.1 Comparison of feature points extraction and matching with different registration algorithms

算法	匹配点
SIFT+KNN	12
SURF+KNN	11
LoFTR	22
Line feature augmented LoFTR	36

在本实验中，使用 LoFTR 对光学图片和点云强度图进行配准，分别在正面和侧面

获得了 36 对和 21 对匹配特征点对，并基于这些点计算了单应性矩阵，以对光学图片进行透视变换，进一步获得的分辨率分别为 1.66 pixel/mm 和 1.28 pixel/mm。

5.5 裂缝识别与量化

向 YOLOv8-CBAM-seg 模型加载训练好的参数，向其输入透视变换后的光学图片，以对裂缝进行实例分割。如图 5.5 所示，YOLOv8-CBAM-seg 算法成功地分割出所有的胶带和正面上的真实裂缝。在 YOLOv8-CBAM-seg 输出的二值图片上使用本文提出的 EOB 算法计算裂缝的宽度（以像素为单位），并通过式 (4.14) 得到裂缝的宽度（以 mm 为单位）。




图 5.5 桥墩裂缝分割结果：（a）正面（b）侧面

Fig. 5.5 Crack segmentation on surfaces of the bridge pier: (a) front (b) side

表 5.2 和表 5.3 分别展示了桥墩正面和侧面的裂缝宽度计算结果：桥墩正面的相对误差均值为 2.48%，相对误差标准差为 8.49%；桥墩侧面的相对误差均值为 11.74%，相对误差标准差为 13.57%。这些结果表明，本文所提出的方法在平面表面上的准确性和稳定性优于在曲面表面上的表现。另一方面，计算结果的误差随着裂缝宽度的不同而变化，即随着裂缝宽度的减小，测量误差显著增加。在真实裂缝方面，真实裂缝的计算宽度为 3.47mm，相较于实际宽度 3.91mm，其相对误差为-11.25%，证明了本文方法的实际有效性；使用 Qiu 等^[38]的方法对裂缝进行长度量化，其长度为 0.33m。总体而言，裂缝宽度量化的准确性是可以接受的，并且可以通过使用更高精度的激光雷达设备进一步提高。本文还评估了裂缝实例分割和宽度计算的计算成本。YOLOv8-CBAM-seg 模型实

现了 53Fps 的实时处理速度，而 EOB 方法计算每张图像大约需要 1s。

表 5.2 裂缝宽度计算结果（桥墩正面）

Tab. 5.2 Results of crack width calculating on the front surface

裂缝	测量宽度， mm	计算宽度，像 素	计算宽度， mm	绝对误差，mm	相对误差，%
1#	10.0	15.57	9.37	-0.63	-6.29%
2#	1.5	2.71	1.63	+0.13	8.74%
3#	2.0	3.73	2.24	+0.24	12.25%
4#	3.0	4.52	2.72	-0.28	-9.32%
5#	5.0	8.11	4.88	-0.12	-2.38%
6#	8.0	13.09	7.88	-0.12	-1.52%
相对误差均值，%		2.48%		相对误差标准差，%	8.49%

表 5.3 裂缝宽度计算结果（桥墩侧面）

Tab. 5.3 Results of crack width calculating on the side surface

裂缝	测量宽度， mm	计算宽度，像 素	计算宽度， mm	绝对误差，mm	相对误差，%
1#	1.5	2.50	1.96	+0.46	30.50%
2#	1.5	2.20	1.73	+0.23	15.15%
3#	2	3.01	2.35	+0.35	17.62%
4#	2	3.01	2.35	+0.35	17.62%
5#	3	4.05	3.17	+0.17	5.83%
6#	3	4.09	3.21	+0.21	6.93%
7#	3	3.00	2.35	-0.65	-21.59%
8#	2	3.02	2.37	+0.37	18.44%
9#	1.5	2.20	1.73	+0.23	15.15%
相对误差均值，%		11.74%		相对误差标准差，%	13.57%

5.6 结果展示

根据点云强度图和光学图片的对应关系，点云中的点和光学图片中的像素建立了对应关系。利用这种对应关系，本文在点云中进行了裂缝的 3D 展示，如图 5.6 所示。桥墩上的裂缝用红色点云标记，突出了裂缝的空间位置和大小。然而，在桥墩的角落处可以观察到纹理缺失，这是由于在收集激光雷达点云数据时角落产生的大量噪声所导致的。




图 5.6 裂缝 3D 展示: (a) 正面 (b) 侧面
Fig. 5.6 3D Visualization of cracks: (a) front (b) side

在此基础上, 根据设计图纸, 本文对这座人行天桥的其他部分进行手动建模, 并将 5.3 节中基于 LiDAR 点云的桥墩模型族载入到项目中, 由此得到了人行天桥 BIM 模型, 完成了裂缝三维量化的结果展示, 如图 5.7 所示。




图 5.7 结果展示
Fig. 5.7 Results display

5.7 本章小结

本章在大连理工大学北门人行桥北侧桥墩上对本文方法的可行性和有效性进行验证。首先，基于 LiDAR 点云的对圆端形截面桥墩建模，其截面参数的提取误差小于 LiDAR 的精度，建模效果较好；接着，在桥墩上进行点云强度图和光学图片配准方法的验证，与传统特征点提取方法（如 SIFT 和 SURF）相比，基于深度学习的 LoFTR 算法在低纹理表面上将特征点数量增加并提高匹配准确性近 100%，当增强线特征时，正确匹配点的数量比原始 LoFTR 算法增加了 64%，证明了轮廓线特征增强策略的有效性；其次，在裂缝的识别和量化方面，桥墩正面的模拟裂缝的宽度量化的相对误差均值为 2.48%，相对误差标准差为 8.49%；桥墩侧面的模拟裂缝的宽度量化相对误差均值为 11.74%，相对误差标准差为 13.57%，而位于桥墩正面的真实裂缝的宽度量化相对误差为 -11.25%，长度量化为 0.33m。结果表明，本文方法在平面表面上的准确性和稳定性优于曲面表面，裂缝宽度量化的相对误差在可接受范围内，且具有较高的实时处理能力；最后，还在点云中进行了裂缝的三维展示，并建立全桥 BIM 模型对结果进行展示。

6 结论与展望

6.1 结论

本文针对桥墩裂缝检测中检测速率较慢、量化不足的现状的难题，提出了基于激光点云和图像数据的桥梁病害三维检测方法。同时，为对裂缝等病害进行展示，还提出了基于 LiDAR 点云的桥墩三维建模方法。使用本文方法在实际工程中得到较好的结果，其主要结论如下：

(1) 基于 LiDAR 点云的桥墩三维建模方法，本文介绍了 LiDAR 采集点云的基本原理，使用 CloudCompare 软件对采集点云进行噪声去除、配准等预处理，总结了桥墩截面的类型主要包括矩形截面、圆形截面、圆端形截面等，提出了 BIM 模型构建的方法：基于 α 形状理论和凸包算法的顶点拟合方法对矩形截面点云进行参数提取，并分析了 α 和截面高度对于长度、宽度参数提取的误差的影响；基于最小二乘法对圆形截面点云进行参数提取，并分析了截面高度对于半径参数提取的误差的影响；基于 OBB 对圆端形截面进行参数提取，并建立了参数化的模型族，叠加点云直观展示了建模的效果。

(2) 点云强度图与光学图片配准方法，本文介绍了深度学习和 CNN 的基本原理，提出了点云强度图生成方法，将点云转换为特征明显的点云强度图以进行配准，提出了基于 LoFTR 的光学图片拼接方法，以扩展图片的场景，增加更多的特征，通过实例验证说明 LoFTR 匹配的特征点对数大于 SIFT、SURF 等传统方法，提出了基于 LoFTR 的点云强度图和光学图片配准方法，对点云强度图中轮廓线特征进行增强以提升配准效果，最终得到了点云和光学图片的对应关系，以此得到了光学图片的分辨率，为下一步病害识别奠定了基础。

(3) 裂缝识别与量化方法，本文将 CBAM 加入 YOLOv8-seg 模型的主干特征提取网络中，提出了 YOLOv8-CBAM-seg 模型，在基于 SDNet2018 的数据集上进行训练、验证和测试，其在精确率（96.7%）和 $mAP@50$ （94.9%）方面优于 U-Net、YOLOv8-seg 等其他方法，本文还提出了基于骨架和图的裂缝宽度量化算法，其包含基于形态学的裂缝交叉点去除和基于 DFS 的裂缝骨架剪枝算法，以及在骨架点上进行宽度量化的 EOB 算法，基于 DFS 的裂缝骨架剪枝算法与 DSE 算法相比不依赖于参数指定，且时间复杂度更低，与 ESD、OB 等算法进行结果比较，EOB 算法结果与骨架点的正交方向更为一致，未出现偏差，在真实骨架固定宽度的拟合数据集上的相对误差的平均值为-5.3%，证明了其量化的准确性较高。

通过在大连理工大学北门人行桥上北侧桥墩的实验，验证了本文方法的有效性和可

行性。对圆端形截面桥墩基于 LiDAR 点云建模，其截面参数的提取误差小于 LiDAR 的精度，建模效果较好。在点云强度图和光学图片配准环节，与传统特征点提取方法（如 SIFT 和 SURF）相比，基于深度学习的 LoFTR 算法在低纹理表面上增加了特征点的数量，匹配准确性提高近 100%。当增强轮廓线特征时，正确匹配点的数量比原始 LoFTR 算法增加了 64%，证明了轮廓线特征增强策略的有效性。在裂缝的识别和量化方面，桥墩正面的模拟裂缝的宽度量化的相对误差均值为 2.48%，相对误差标准差为 8.49%；桥墩侧面的模拟裂缝的宽度量化的相对误差均值为 11.74%，相对误差标准差为 13.57%，而位于桥墩正面的真实裂缝的宽度量化相对误差为 -11.25%，长度量化为 0.33m。结果表明，本文方法在平面表面上的准确性和稳定性优于曲面表面，裂缝宽度量化的相对误差在可接受范围内，且具有较高的实时处理能力。本文还对裂缝在点云上进行了三维展示，并建立了全桥的 BIM 模型进行结果展示。

综上所述，本文提出的基于激光点云和图像数据的混凝土桥墩裂缝三维定量检测方法在桥梁病害检测领域具有重要的理论意义和工程应用价值。

6.2 展望

尽管本文提出的方法在桥梁病害检测中取得了良好的效果，但仍存在一些不足之处和改进空间，未来研究可从以下几个方面展开：

(1) 设备精度的提升：目前的实验中，LiDAR 的精度对裂缝宽度量化结果有一定影响。未来可采用更高精度的 LiDAR 设备，以进一步提高检测精度。

(2) 算法的优化：本文提出的裂缝识别与量化算法在低纹理区域和曲面表面上的表现仍有改进空间。未来可结合更多的深度学习模型和优化策略，进一步提升算法的鲁棒性和适应性。

(3) 多模态数据融合：本文主要研究了点云和光学图片的融合，未来可探索引入更多数据模态（如热成像、红外图像等），以增强病害检测的全面性和准确性。

通过以上改进和拓展，本文提出的方法有望在桥梁病害检测领域发挥更大的作用，为桥梁的安全维护和管理提供更加高效、精准的技术支持。

参考文献

- [1] 谭浩. 无人机倾斜摄影测量的真实场景三维重建方法研究 [J]. 科学技术创新, 2025, (07): 108-111.
- [2] 彭飞, 王艳艳. 无人机倾斜摄影与地面激光点云融合建模 [J]. 经纬天地, 2025, (01): 49-52.
- [3] 付晓凡. 基于 RGB-D 相机的快速旋转式大场景三维地图构建方法研究 [D]. 苏州大学, 2021.
- [4] 石强, 邵振峰, 杜志强, et al. 基于地面激光扫描技术的矿区地形图更新 [J]. 测绘信息与工程, 2012, 37(01): 33-35.
- [5] 曹荣贞. 基于地面激光雷达点云数据的单木三维建模及生物量估算研究 [D]. 东北林业大学, 2024.
- [6] Fang Y, Mitoulis S-A, Boddice D, et al. Scan-to-BIM-to-Sim: Automated reconstruction of digital and simulation models from point clouds with applications on bridges [J]. Results in Engineering, 2025, 25: 104289.
- [7] Zhaoyang X, Ting W. Research on BIM Reconstruction Method Using Semantic Segmentation Point Cloud Data Based on PointNet [J]. IOP Conference Series: Earth and Environmental Science, 2021, 719(2): 022042.
- [8] Yan Y, Wang Z, Xu C, et al. GEOP-Net: Shape Reconstruction of Buildings From LiDAR Point Clouds [J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.
- [9] Tian X, Jian Y, Long C. Automated semantic segmentation of bridge point cloud based on local descriptor and machine learning [J]. Automation in Construction, 2022, 133: 103992.
- [10] Shengjun T, Xiaoming L, Xianwei Z, et al. BIM generation from 3D point clouds by combining 3D deep learning and improved morphological approach [J]. Automation in Construction, 2022, 141: 104422.
- [11] Mehranfar M, Arefi H, Alidoost F. Knowledge-based 3D reconstruction of bridge structures using UAV-based photogrammetric point cloud [J]. Journal of Applied Remote Sensing, 2021, 15(4): 044503.
- [12] Mafipour M S, Simon V, André B. Automated geometric digital twinning of bridges from segmented point clouds by parametric prototype models [J]. Automation in Construction, 2023, 156: 105101.
- [13] 赵馨怡, 郭晓. 基于 BIM 和三维激光扫描技术的建设工程质量检测方法研究 [J]. 土木建筑工程信息技术, 2020, 12(05): 131-134.
- [14] Jong Won M, Thomas C, Fernanda L. Semantic segmentation of point clouds of building interiors with deep learning: Augmenting training datasets with synthetic BIM-based point clouds [J]. Automation in Construction, 2020, 113: 103144.
- [15] Duan L, Geng H, Zeng J, et al. Fast and Accurately Measuring Crack Width via Cascade Principal Component Analysis [M]. Proceedings of the 1st ACM International Conference on Multimedia in Asia. Beijing, China; Association for Computing Machinery. 2020: 22.
- [16] Agdas D, Rice J A, Martinez J R, et al. Comparison of Visual Inspection and Structural-Health Monitoring As Bridge Condition Assessment Methods [J]. Journal of Performance of Constructed Facilities, 2016, 30(3): 04015049.
- [17] Talab A M A, Huang Z, Xi F, et al. Detection crack in image using Otsu method and multiple filtering

- in image processing techniques [J]. *Optik*, 2016, 127(3): 1030-1033.
- [18]Hoang N-D, Nguyen Q-L. Metaheuristic Optimized Edge Detection for Recognition of Concrete Wall Cracks: A Comparative Study on the Performances of Roberts, Prewitt, Canny, and Sobel Algorithms [J]. *Advances in Civil Engineering*, 2018, 2018: 7163580.
- [19]Hoang N-D, Quoc-Lam N, Van-Duc T. Automatic recognition of asphalt pavement cracks using metaheuristic optimized edge detection algorithms and convolution neural network [J]. *Automation in Construction*, 2018, 94: 203-213.
- [20]薛浪, 曾庆立, 周佳凯, et al. 基于 FPGA 的直线检测设计与实现 [J]. *现代电子技术*, 2025, 48(09): 43-48.
- [21]Chen X, Li J, Huang S, et al. An Automatic Concrete Crack-Detection Method Fusing Point Clouds and Images Based on Improved Otsu's Algorithm [J]. *Sensors*, 2021, 21(5): 1581.
- [22]Kim B-C, Son B-J. Crack Detection of Concrete Images Using Dilatation and Crack Detection Algorithms [J]. *Applied Sciences*, 2023, 13(16): 9238.
- [23]Hong Y, Wenkang T, Jiaxin L, et al. Rapid Crack Detection Method of High-grade Cement Concrete Pavement [J]. *Journal of Physics: Conference Series*, 2020, 1622(1): 012102.
- [24]Kaiyang Z, Dong L, Jintao H, et al. Single micro-damage identification and evaluation in concrete using digital image correlation technology and wavelet analysis [J]. *Construction and Building Materials*, 2021, 267: 120951.
- [25]Jia H, Wei B, Liu G, et al. A Semi-Automatic Method for Extracting Small Ground Fissures from Loess Areas Using Unmanned Aerial Vehicle Images [J]. *Remote Sensing*, 2021, 13(9): 1784.
- [26]Zheng M, Lei Z, Zhang K. Intelligent detection of building cracks based on deep learning [J]. *Image and Vision Computing*, 2020, 103: 103987.
- [27]Zhang Q, Barri K, Babanajad S K, et al. Real-Time Detection of Cracks on Concrete Bridge Decks Using Deep Learning in the Frequency Domain [J]. *Engineering*, 2021, 7(12): 1786-1796.
- [28]Tran T S, Nguyen S D, Lee H J, et al. Advanced crack detection and segmentation on bridge decks using deep learning [J]. *Construction and Building Materials*, 2023, 400: 132839.
- [29]Wang W, Su C. Automatic concrete crack segmentation model based on transformer [J]. *Automation in Construction*, 2022, 139: 104275.
- [30]Shi Z, Jin N, Chen D, et al. A comparison study of semantic segmentation networks for crack detection in construction materials [J]. *Construction and Building Materials*, 2024, 414: 134950.
- [31]Liu J, Yang Z, Qi H, et al. Deep learning-assisted automatic quality assessment of concrete surfaces with cracks and bugholes [J]. *Advanced Engineering Informatics*, 2024, 62: 102577.
- [32]Woo S, Park J, Lee J Y, et al. CBAM: Convolutional Block Attention Module [M]. Springer, Cham. 2018: 3-19.
- [33]Wang N, Zhang Z, Hu H, et al. Underground Defects Detection Based on GPR by Fusing Simple Linear Iterative Clustering Phash (SLIC-Phash) and Convolutional Block Attention Module (CBAM)-YOLOv8 [J]. *IEEE Access*, 2024, 12: 25888-25905.
- [34]Zhang C, Chen X, Liu P, et al. Automated detection and segmentation of tunnel defects and objects using YOLOv8-CM [J]. *Tunnelling and Underground Space Technology*, 2024, 150: 105857.
- [35]Blum H, Nagel R N. Shape description using weighted symmetric axis features [J]. *Pattern Recognition*, 1978, 10(3): 167-180.

- [36]Zhang T Y, Suen C Y. A fast parallel algorithm for thinning digital patterns [J]. Commun ACM, 1984, 27(3): 236–239.
- [37]Youzhi T, Allen A Z, Lei L, et al. Pixel-level pavement crack segmentation with encoder-decoder network [J]. Measurement, 2021, 184: 109914.
- [38]Qiu S, Wang W, Wang S, et al. Methodology for accurate AASHTO PP67-10-based cracking quantification using 1-mm 3D pavement images [J]. Journal of Computing in Civil Engineering, 2017, 31(2): 04016056.
- [39]Minh Dang L, Wang H, Li Y, et al. Deep learning-based masonry crack segmentation and real-life crack length measurement [J]. Construction and Building Materials, 2022, 359: 129438.
- [40]Kim H, Lee J, Ahn E, et al. Concrete Crack Identification Using a UAV Incorporating Hybrid Image Processing [J]. Sensors, 2017, 17(9): 2052.
- [41]Liu Y-F, Nie X, Fan J-S, et al. Image-based crack assessment of bridge piers using unmanned aerial vehicles and three-dimensional scene reconstruction [J]. Computer-Aided Civil and Infrastructure Engineering, 2020, 35(5): 511-529.
- [42]Woo H-J, Seo D-M, Kim M-S, et al. Localization of Cracks in Concrete Structures Using an Unmanned Aerial Vehicle [J]. Sensors, 2022, 22(17): 6711.
- [43]Yu R, Li P, Shan J, et al. Multi-feature driven rapid inspection of earthquake-induced damage on building facades using UAV-derived point cloud [J]. Measurement, 2024, 232: 114679.
- [44]Jiang H, Li Q, Jiao Q, et al. Extraction of Wall Cracks on Earthquake-Damaged Buildings Based on TLS Point Clouds [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11(9): 3088-3096.
- [45]Wu J, Shi Y, Wang H, et al. Surface Defect Detection of Nanjing City Wall Based on UAV Oblique Photogrammetry and TLS [J]. Remote Sensing, 2023, 15(8): 2089.
- [46]Cabaleiro M, Lindenbergh R, Gard W F, et al. Algorithm for automatic detection and analysis of cracks in timber beams from LiDAR data [J]. Construction and Building Materials, 2017, 130: 41-53.
- [47]Awad M M. Toward Robust Segmentation Results Based on Fusion Methods for Very High Resolution Optical Image and LiDAR Data [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2017, 10(5): 2067-2076.
- [48]Elamin A, El-Rabbany A. UAV-Based Image and LiDAR Fusion for Pavement Crack Segmentation [J]. Sensors, 2023, 23(23): 9315.
- [49]Peng S, Ma H, Zhang L. Automatic Registration of Optical Images with Airborne LiDAR Point Cloud in Urban Scenes Based on Line-Point Similarity Invariant and Extended Collinearity Equations [J]. Sensors, 2019, 19(5): 1086.
- [50]Xu J, Yao C, Ma H, et al. Automatic Point Cloud Colorization of Ground-Based LiDAR Data Using Video Imagery without Position and Orientation System [J]. Remote Sensing, 2023, 15(10): 2658.
- [51]夏榕成. 基于点云数据的大桥钢构梁尺寸参数检测算法研究 [D]. 江西理工大学, 2023.
- [52]Besl P J, McKay N D. A method for registration of 3-D shapes [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1992, 14(2): 239-256.
- [53]刘龄嘉. 桥梁工程（第二版） [M]. 人民交通出版社, 2013.
- [54]Matas J, Chum O. Randomized RANSAC with sequential probability ratio test [M]. Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1. 2005: 1727-1732.

- [55]Qiu Q, Lau D. Real-time detection of cracks in tiled sidewalks using YOLO-based method applied to unmanned aerial vehicle (UAV) images [J]. Automation in Construction, 2023, 147: 104745.
- [56]Sun Z, Liu J, Li P, et al. DGAP-YOLO: A Crack Detection Method Based on UAV Images and YOLO; proceedings of the Advanced Intelligent Computing Technology and Applications, Singapore, F 2024//, 2024 [C]. Springer Nature Singapore.
- [57]Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need [J/OL] 2017, <https://doi.org/10.48550/arXiv.1706.03762>.
- [58]Jiaming S, Zehong S, Yuang W, et al. LoFTR: Detector-Free Local Feature Matching with Transformers [J/OL] 2021, <https://doi.org/10.48550/arXiv.2104.00680>.
- [59]Zhengqi L, Noah S. MegaDepth: Learning Single-View Depth Prediction from Internet Photos [M]. Computer Vision and Pattern Recognition (CVPR). 2018.
- [60]Doyle L, Mould D. Augmenting photographs with textures using the Laplacian pyramid [J]. The Visual Computer, 2019, 35(10): 1489-1500.
- [61]Lowe D G. Distinctive Image Features from Scale-Invariant Keypoints [J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [62]Bay H, Tuytelaars T, Van Gool L. SURF: Speeded Up Robust Features [M]. Computer Vision – ECCV 2006. Berlin, Heidelberg; Springer Berlin Heidelberg. 2006: 404-417.
- [63]Yoon S, Kim A. Line as a Visual Sentence: Context-Aware Line Descriptor for Visual Localization [J]. IEEE Robotics and Automation Letters, 2021, 6(4): 8726-8733.
- [64]Raguram R, Chum O, Pollefeys M, et al. USAC: A Universal Framework for Random Sample Consensus [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(8): 2022-2038.
- [65]Daniel B, Jana N, Jiri M. MAGSAC: marginalizing sample consensus [J]. 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019: 10189-10197.
- [66]Edelsbrunner H, Mcke E P. Three-dimensional alpha shapes [J]. ACM Trans Graph, 1994, 13(1): 43-72.
- [67]Arun M, Sumathi P. Crack detection using image processing: A critical review and analysis [J]. Alexandria Engineering Journal, 2018, 57(2): 787-798.
- [68]Li Z, Miao Y, Torbaghan M E, et al. Semi-automatic crack width measurement using an OrthoBoundary algorithm [J]. Automation in Construction, 2024, 158: 105251.
- [69]Long J, Shelhamer E, Darrell T. Fully Convolutional Networks for Semantic Segmentation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(4): 640-651.
- [70]Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation [M]. Springer International Publishing. 2015: 234-241.
- [71]He K, Gkioxari G, Dollár P, et al. Mask R-CNN; proceedings of the 2017 IEEE International Conference on Computer Vision (ICCV), F 22-29 Oct. 2017, 2017 [C].
- [72]Dillon R, Jordan K, Jacqueline H, et al. Real-Time Flying Object Detection with YOLOv8 [J/OL] 2023, <https://doi.org/10.48550/arXiv.2305.09972>.
- [73]Qiu Q, Lau D. Assessment of Trees' Structural Defects via Hybrid Deep Learning Methods Used in Unmanned Aerial Vehicle (UAV) Observations [J]. Forests, 2024, 15(8): 1374.
- [74]Dorafshan S, Thomas R J, Maguire M. SDNET2018: An annotated image dataset for non-contact

- concrete crack detection using deep convolutional neural networks [J]. Data in Brief, 2018, 21: 1664-1668.
- [75]Lin T-Y, Maire M, Bourdev S J B L D, et al. Microsoft COCO: Common Objects in Context [M]. Computer Vision -- ECCV 2014. 2014.
- [76]Abbas Ahmadi S K, Amir G. An integrated machine learning model for automatic road crack detection and classification in urban areas [J]. International Journal of Pavement Engineering, 2022, 23(10): 3536-3552.
- [77]Cheng H D, Miyojim M. Automatic pavement distress detection system [J]. Information Sciences, 1998, 108(1): 219-240.
- [78]Blum H. Biological shape and visual science (part I) [J]. Journal of Theoretical Biology, 1973, 38(2): 205-287.
- [79]Ong J C H, Ismadi M-Z P, Wang X. A hybrid method for pavement crack width measurement [J]. Measurement, 2022, 197: 111260.
- [80]Bai X, Latecki L J. Discrete Skeleton Evolution [M]. Energy Minimization Methods in Computer Vision and Pattern Recognition. Berlin, Heidelberg; Springer Berlin Heidelberg. 2007: 362-374.
- [81]Wang W, Zhang A, Wang K C P, et al. Pavement Crack Width Measurement Based on Laplace's Equation for Continuity and Unambiguity [J]. Computer-Aided Civil and Infrastructure Engineering, 2018, 33(2): 110-123.
- [82]Ester M, Kriegel H-P, Sander J r, et al. A density-based algorithm for discovering clusters in large spatial databases with noise [M]. Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. AAAI Press. 1996: 226-231.
- [83]Shi Y, Cui L, Qi Z, et al. Automatic road crack detection using random structured forests [J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17(12): 3434-3445.
- [84]Chun L, Chao-Sheng T, Bin S, et al. Automatic quantification of crack patterns by image processing [J]. Computers & Geosciences, 2013, 57: 77-80.